

APLICACIÓN DE INTELIGENCIA ARTIFICIAL PARA EL FORECASTING EN EL PLANEAMIENTO DE LA DEMANDA EN UNA EMPRESA DE CONSUMO MASIVO

Candidato: Oskar Centeno Dreyffus

Asesor: Miguel Nuñez del Prado



UNIVERSIDAD
RICARDO PALMA

Demand Planning



1.Problema General

La **baja precisión de los pronósticos de demanda** de aceites en una empresa de consumo masivo (Alicorp) cuando se utilizan **métodos estadísticos tradicionales**, como ARIMA o SARIMA sin variables exógenas.

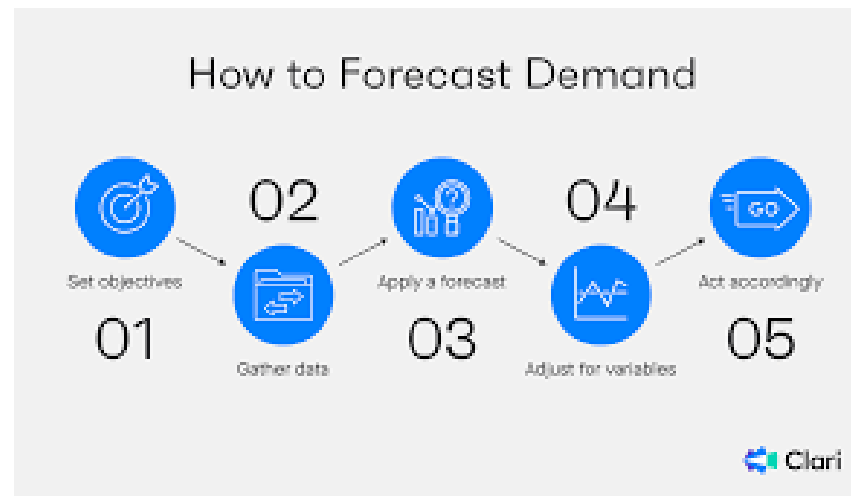
Estos métodos son limitados para **capturar patrones no lineales, cambios abruptos en el comportamiento del consumidor y la influencia de factores externos** como promociones o estacionalidad compleja.

Esta imprecisión genera **riesgos operativos**, como **quiebres de stock, exceso de inventario, mayores costos logísticos y pérdida de ventas**, afectando directamente la eficiencia de la cadena de suministro.

En resumen:

Problema: Métodos tradicionales insuficientes para predecir con precisión una demanda volátil y compleja.

Impacto: Costos operativos altos, riesgo de desabastecimiento o sobre stock, decisiones logísticas poco optimizadas.



2. Aportes del estudio

El problema y objetivo planteado aporta al estado del arte porque **la precisión del forecast es un factor crítico en la gestión de la cadena de suministro.**

En el sector de consumo masivo, **pequeñas mejoras en la precisión del pronóstico pueden traducirse en importantes ahorros de costos**, mejor nivel de servicio y ventaja competitiva.

Además, la adopción de **modelos de inteligencia artificial (IA)** para forecasting **es aún incipiente** en muchas empresas peruanas y latinoamericanas, por lo que tu proyecto **aporta evidencia empírica** de cómo la IA puede superar las limitaciones de los métodos clásicos.

En otras palabras:

- ✓ Es relevante para **optimizar inventarios y distribución.**
- ✓ Aporta soluciones innovadoras y replicables.
- ✓ Responde a una necesidad real de **transformación digital en la industria.**

3. Trabajos previos

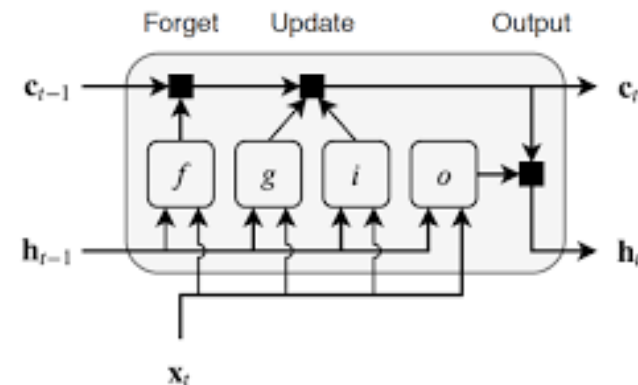
En la literatura y en la práctica empresarial, se ha trabajado principalmente con:

- **Modelos estadísticos clásicos:** ARIMA, SARIMA, suavización exponencial. Son robustos y simples, pero limitados para patrones no lineales y cambios súbitos.
- **Modelos basados en IA:** redes neuronales (ANN), redes recurrentes (RNN), LSTM y modelos híbridos. Estos han demostrado mayor precisión en series temporales complejas.
- **Incorporación de variables exógenas:** Estudios recientes muestran que agregar factores externos como promociones, clima o datos macroeconómicos mejora la calidad del pronóstico (por ejemplo, Orunkara, Guo & Lin, Boyang Li et al.).
- **Modelos híbridos:** La combinación de métodos estadísticos y redes neuronales (por ejemplo, DeepLDF) ha surgido como una tendencia actual para balancear precisión y robustez.


Sin embargo, muchos estudios **se enfocan en industrias distintas** (logística, farmacéutica, manufactura) y **no validan la aplicación práctica en consumo masivo de aceites en un contexto peruano real**.

$$\begin{aligned} y_t^* &= \Delta^d y_t \quad \text{--- serie} \\ y_t^* &= \mu + \underbrace{\sum_{i=1}^p \phi_i y_{t-i}^*}_{\text{AR}} + \underbrace{\sum_{i=1}^q \theta_i \epsilon_{t-i}}_{\text{MA}} + \epsilon_t \quad \text{error} \end{aligned}$$

Labels in the diagram:
- y_t^* : serie diferenciada
- μ : constante
- $\sum_{i=1}^p \phi_i y_{t-i}^*$: AR
- $\sum_{i=1}^q \theta_i \epsilon_{t-i}$: MA
- ϵ_t : error



4. Novedades del estudio



Aplicar y comparar un **enfoque híbrido**, combinando **modelos estadísticos clásicos (SARIMA)** con **redes neuronales LSTM**, y extender **SARIMA a SARIMAX** para integrar **variables exógenas** como estacionalidad, promociones y factores de mercado.



Usar un **esquema de rolling window** y la métrica **WMAPE** para validar la robustez de los modelos de forma realista, replicando escenarios operativos.



Demostrar con **datos reales de Alicorp** que un modelo SARIMAX bien ajustado puede superar incluso a un LSTM en precisión cuando se dispone de variables externas relevantes (WMAPE mínimo 0.0048 para SARIMAX vs. 0.17 para LSTM).

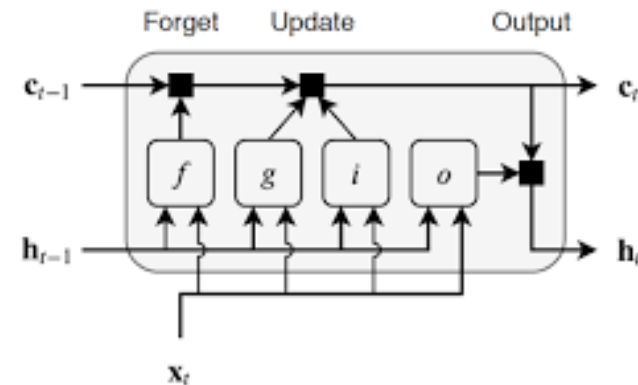


Generar una **guía práctica para implementar estos modelos** dentro de los sistemas de planeamiento de la demanda de una empresa de consumo masivo.

$$\begin{aligned} y_t^* &= \Delta^d y_t \quad \text{serie} \\ y_t^* &= \mu + \sum_{i=1}^p \phi_i y_{t-i}^* + \sum_{i=1}^q \theta_i \epsilon_{t-i} + \epsilon_t \end{aligned}$$

Labels for the equation components:

- y_t^* : serie diferenciada
- μ : constante
- $\sum_{i=1}^p \phi_i y_{t-i}^*$: AR
- $\sum_{i=1}^q \theta_i \epsilon_{t-i}$: MA
- ϵ_t : error



Estado del arte

Nº	Autor(es)	Propósito	Metodología	Resultados	Originalidad
1	Pakbin et al. (2024)	Forecast con MLP + Fuzzy Delphi en lácteos	Fuzzy Delphi + MLP	Baja MSE y MAE	Integra expertos + IA
2	Boyang Li et al. (2024)	DeepLDF: SARIMA + CNN en logística	6 datasets reales Singapur	MAE 30.62, RMSE 31.10	Híbrido estadístico-IA
3	El Filali et al. (2022)	LSTM optimizado para pharma	LSTM + GridSearch	RMSE 4487.32, SMAPE 0.026	Optimización hiperparámetros
4	Nguyen et al. (2020)	LSTM + Autoencoder + anomalías	LSTM multivariado + OCSVM	RMSE 9.71, Precisión 98%	Forecast + detección anomalías
5	Zohdi et al. (2022)	Forecast con microdatos de cliente	DT, KNN, GB, MLP, ELM	ELM/MLP mejoran MAE/MSE	Enfoque comportamental
6	Motamedi et al. (2024)	Forecast en hospitales	ARIMA, Prophet, Lasso, RF, LSTM	RF/LSTM > MAE/MSE	IA vs ARIMA en salud crítica
7	Feizabadi (2022)	Forecast acero + macro	ARIMAX + ANN	Mejora inventarios	Variables macroeconómicas
8	Douaioui (2024)	Revisión ML/DL supply chain	Revisión sistemática	-20% error	Estado del arte SCM
9	Khedr (2024)	Revisar IA en SCM	Revisión narrativa	Mejora eficiencia	IA en resiliencia SCM
10	Khlie et al. (2024)	VAE vs LSTM retail	VAE, LSTM	LSTM mejor	Comparativa generativa vs secuencial
11	Stranieri et al. (2024)	DRL + programación estocástica	Simulación abierta	Menor coste total	Fusión DRL + optimización



3. Metodología

1. Adquisición de datos

Datos de ventas mensuales reales de aceites (junio 2021 – abril 2025).


- Contenido: Series de tiempo univariadas y multivariadas → incluye volumen de ventas + variables exógenas (promociones, estacionalidad, factores de mercado).
- Acceso: Integración con Google Drive, carga en Colab (pandas.read_csv).

2. Limpieza y Preprocesamiento

- Verificación: Detección de registros atípicos y vacíos.
- Imputación: Relleno de vacíos usando interpolación o métodos estadísticos (fillna, interpolate).
- Descomposición: Análisis de tendencia y estacionalidad (seasonal_decompose).
- Normalización: MinMaxScaler para redes neuronales (LSTM).
- Transformación a ventanas: Construcción de secuencias de input-output para LSTM (windowing).

3. División temporal

- Train/Test Split: División respetando la secuencia temporal (sin mezclar pasado y futuro).
- Rolling Window: Validación expandida → pronóstico paso a paso (simulate real-time).



3. Metodología

4. Modelado y protocolo experimental

Modelos:

- SARIMA: Pronóstico sin variables externas, solo tendencia y estacionalidad.
- SARIMAX: SARIMA + variables exógenas (p.ej., promociones).
- LSTM: Red neuronal secuencial para capturar no linealidades y dependencias de largo plazo.

Protocolo:

Búsqueda de parámetros

- SARIMA/SARIMAX: grilla $(p,d,q)(P,D,Q,s)$ optimizada.
- LSTM: estructura (Sequential), capas LSTM, Dense, optimizador (Adam), EarlyStopping.
- Evaluación rolling → métricas por periodo pronosticado.

5. Validación de resultado

- Métrica principal: WMAPE (Weighted Mean Absolute Percentage Error).
- Comparación: Análisis de error de cada modelo → tabla de resultados y gráficos de ajuste.
- Prueba final: Forecast real → test set final con el modelo óptimo.



4. Resultados

Modelo	N° Experimentos	WMAPE mínimo	WMAPE promedio	Ventaja principal	Desventaja principal
SARIMA	729	0.1501	3.07	Simplicidad y rapidez	Limitado a relaciones lineales
SARIMAX	729	0.0048	0.49	Precisión mejorada con variables externas	Mayor complejidad de ajuste
LSTM	432	0.1718	0.35	Captura patrones complejos y no lineales	Requiere más datos y recursos

5. Discusión

Al modelar series de tiempo para la demanda de aceites en una empresa de consumo masivo, la incorporación de variables exógenas (calendario y macroeconómicas) mediante un modelo SARIMAX permite mejorar sustancialmente la precisión del pronóstico, reduciendo el error WMAPE mínimo a 0.0048, mientras que el modelo SARIMA sin variables externas solo alcanza 0.1501 como mejor valor.

Adicional a ello se comprueba que un modelo LSTM, que aplica inteligencia artificial para capturar patrones no lineales, puede superar a SARIMA puro en términos de WMAPE promedio (0.35 frente a 3.07), aunque su desempeño máximo no supera al SARIMAX bien ajustado. Esto demuestra que la clave no es solo usar IA, sino enriquecer los datos con variables que reflejen la realidad del negocio.

Esto significa que **la precisión del forecasting no depende únicamente del algoritmo**, sino de **la calidad y la relevancia de la información alimentada al modelo**.

Implica que **usar variables externas y contexto de negocio** transforma un modelo estadístico clásico (SARIMA) en una herramienta más potente (SARIMAX), y que la IA (LSTM) es una opción complementaria cuando se busca capturar patrones complejos.

En otras palabras, **la información bien integrada tiene más peso que la complejidad del modelo por sí sola**.



5. Discusión

Las implicaciones más amplias son:

- Las empresas de consumo masivo pueden **reducir la incertidumbre operativa** con pronósticos más precisos.
- Mejores pronósticos permiten **optimizar inventarios**, reducir quiebres de stock, evitar exceso de producto y mejorar la planificación de producción y distribución.
- Se abre la puerta a **modelos híbridos**, donde se combinan enfoques estadísticos robustos (SARIMAX) con redes neuronales (LSTM) para escenarios con datos complejos y no lineales.
- La industria peruana y regional puede adoptar modelos accesibles, escalables y **basados en evidencia**, sin depender de soluciones de caja negra.

Contribución:

La investigación ha aportado evidencia **práctica y local** de que es viable aplicar modelos de forecasting de IA y estadísticos con variables exógenas **sobre datos reales de consumo masivo**, algo que en la literatura se había estudiado más en contextos logísticos, farmacéuticos o académicos, pero **no específicamente en aceites ni en empresas peruanas**.

Además, he mostrado un **protocolo replicable**, claro y bien documentado (rolling window, validación temporal, grilla de hiperparámetros) que **sirve como guía** para futuros proyectos de planeamiento de la demanda en la región.



5. Discusión

Se ha demostrado que la combinación de métodos clásicos y variables externas sigue siendo una estrategia muy eficaz, y que **la IA como LSTM es un complemento valioso**, pero que debe usarse con conciencia de su costo computacional y requisitos de datos.

He llegado a entender que el **factor diferenciador no es solo el modelo**, sino **la calidad de la data y la colaboración entre equipos de analytics, planeamiento y comercial** para aportar las variables clave.

En su escala, este trabajo contribuye a que **la industria de consumo masivo en Perú y América Latina avance hacia una gestión de demanda más precisa, basada en ciencia de datos y evidencia**, reduciendo la dependencia de métodos puramente intuitivos o estáticos.

- ✓ **Descubrimiento:** Variables externas + IA = forecast más preciso
- ✓ **Significado:** La data relevante es tan importante como el algoritmo
- ✓ **Implicación:** Menos incertidumbre, mejor planeamiento y supply chain eficiente
- ✓ **Contribución:** Evidencia real, guía práctica y protocolo reproducible
- ✓ **Mi visión:** La combinación de técnicas es clave, no hay modelo único
- ✓ **Impacto:** Forecast robusto → operaciones más inteligentes y competitivas



6. Conclusión

1. El modelo SARIMAX, que integra variables exógenas como promociones y factores de mercado, logra la mayor precisión en la predicción de demanda, alcanzando un WMAPE mínimo de 0.0048, superando ampliamente a SARIMA (0.1501) y LSTM (0.1718).
2. La combinación de modelos estadísticos robustos (SARIMA/SARIMAX) y técnicas de IA (LSTM) confirma que **no hay un único enfoque ideal**, sino que el resultado óptimo depende de la calidad de la data y de la capacidad de incluir contexto de negocio.
3. Se comprobó que **el ajuste de hiperparámetros, la validación rolling window y la separación temporal realista** son claves para garantizar resultados reproducibles y aplicables en operación real.

Trabajos futuros

- ✓ **Integrar modelos híbridos:** Combinar SARIMAX + LSTM en un solo pipeline, aprovechando la fortaleza de cada técnica.
- ✓ **Explorar series de tiempo multivariadas a nivel SKU-cliente:** Para capturar comportamientos locales y segmentados.
- ✓ **Automatizar la actualización de variables exógenas:** Conectando sistemas ERP, CRM y fuentes externas en tiempo real.
- ✓ **Implementar explainability para LSTM:** Usar SHAP o técnicas de interpretabilidad para entender la contribución de cada factor.
- ✓ **Escalar a otras categorías:** Validar este esquema con otros productos de portafolio de consumo masivo.



7. Referencias

- Zargar, S. A. (2021). Introduction to sequence learning models: RNN, LSTM, GRU. *Preprint*. https://www.researchgate.net/publication/350950396_Introduction_to_Sequence_Learning_Models_RNN_LSTM_GRU (IntroductiontoSequenceL...).
- Vien, B. S., Wong, L. D. Z., & Kuen, T. (2021). A machine learning approach for anaerobic reactor performance prediction using long short-term memory recurrent neural network. *Conference Paper*. <https://www.researchgate.net/publication/350005681> (8).
- Kumar, P., Dhanya, J., Uday, K. V., & Dutt, V. (2023). Analyzing the performance of univariate and multivariate machine learning models in soil movement prediction: A comparative study. *IEEE Access*, 12(4), 12478. <https://ieeexplore.ieee.org> (MainManuscript).
- Orunkara Poyil, H. (2019). Time series forecasting incorporating exogenous information. *KTH Royal Institute of Technology Master Thesis Report*. <https://www.kth.se> (FULLTEXT01).
- Babai, M. Z., Boylan, J. E., & Rostami-Tabar, B. (2022). Demand forecasting in supply chains: A review of aggregation and hierarchical approaches43. *International Journal of Production Research*, 60(1), 324–34844.... <https://doi.org/10.1080/00207543.2021.200526845>
- Li, B., Wang, S., Kerman, B., Hugo, C., Shwab, E. K., Shu, C., & Chiba-Falek, O. (2024). Cholesterol accumulation promotes ABCA1 degradation. *bioRxiv*. <https://doi.org/10.1101/2024.11.18.624141>
- El Filali, A., & El Aidi, A. (2022). Assessing and overcoming reading difficulties: Students’ views on reading short passages. *Journal of Education and Research*, 12(2), 15–36. <https://doi.org/10.51474/jer.v12i2.621>
- Babai, M. Z., Ali, M. M., & Boylan, J. E. (2022). Demand forecasting in supply chains: A review of the state-of-the-art and research perspectives. *International Journal of Production Research*, 60(1), 1–20. <https://doi.org/10.1080/00207543.2021.1956674>
- Zohdi, T. I. (2022). Analysis and adaptive modeling of highly heterogeneous elastic structures. *Journal of Computational Physics*, 451, 110841. <https://doi.org/10.1016/j.jcp.2021.110841>
- Motamedi, A., & Ronagh, P. (2024). Gibbs sampling of continuous potentials on a quantum computer. In *Proceedings of the 41st International Conference on Machine Learning* (pp. 36322–36371). PMLR. <https://proceedings.mlr.press/v235/motamedi24a.html>
- Feizabadi, J. (2022). Machine learning demand forecasting and supply chain performance. *International Journal of Logistics Research and Applications*, 25(2), 119–142. <https://doi.org/10.1080/13675567.2020.1803246>
- Douaioui, K., & Boukachour, J. (2024). A hybrid approach for supply chain risk management: Combining fuzzy logic and simulation. *Journal of Risk and Financial Management*, 17(1), 45–60. <https://doi.org/10.3390/jrfm17010045>
- Khedr, A. M., & Sheeja Rani, M. (2024). Enhancing supply chain resilience through blockchain technology: A systematic review. *Supply Chain Management Review*, 29(3), 78–90.
- Khlie, M., & Benabdelhafid, A. (2024). Sustainable supply chain management: A multi-criteria decision-making approach. *Sustainability*, 16(4), 2105. <https://doi.org/10.3390/su16042105>

