



UNIVERSIDAD RICARDO PALMA

ESCUELA DE POSGRADO

MAESTRÍA EN CIENCIA DE LOS DATOS

**APLICACIÓN DE MODELOS DE INTELIGENCIA ARTIFICIAL
PARA EL FORECASTING EN EL PLANEAMIENTO DE LA
DEMANDA EN UNA EMPRESA DE CONSUMO MASIVO.**

PROYECTO DE TESIS

**PARA OPTAR EL GRADO ACADÉMICO DE MAESTRO EN
CIENCIA DE LOS DATOS**

AUTOR

CENTENO DREYFFUS, OSKAR UGO

(ORCID: 0009-0009-7037-8731)

ASESOR

(ORCID:0000-0000-0000)

LIMA, PERÚ – 2025

Metadatos Complementarios:

Datos de autor

Centeno Dreyffus, Oskar Ugo

Tipo de documento de identidad del autor:

DNI

Número de documento de identidad del autor:

75905964

Datos del asesor

Núñez Del Prado Cortez, Miguel

Tipo de documento de identidad del asesor:

DNI

Número de documento de identidad del asesor:

42660446

Datos del jurado

DEDICATORIA

A mi familia quienes creen en mi y en lo que puedo lograr.

A mi novia por su apoyo y brindarme la calma en los momentos más complejos en el tramo final del programa de maestría.

A mis compañeros de maestría quienes son parte vital de la culminación de este trabajo de investigación.

AGRADECIMIENTO

Quiero expresar mi más sincero agradecimiento a mis compañeros de la maestría en ciencia de datos, sin el apoyo y energía de ellos en los momentos más complejos este proyecto no podría ser una realidad.

Así mismo agradecer a mi asesor de tesis quien me brindó el empuje y guía para culminar este trabajo adecuadamente.

ÍNDICE

CAPÍTULO I: PLANTEAMIENTO DEL ESTUDIO

- 1.1. Descripción y delimitación del Problema
 - 1.1.1. Formulación del problema (Problemática)
 - 1.1.2. Problema central del Estudio
- 1.2. Objetivos de la Investigación
 - 1.2.1. Objetivo general
 - 1.2.2. Objetivos específicos
- 1.3. Importancia del Estudio
- 1.4. Justificación del Estudio (aporte, contribución)
- 1.5. Limitaciones del Estudio

CAPÍTULO II: MARCO TEÓRICO

- 2.1. Marco histórico (sólo en caso necesario si el tema lo amerita)
- 2.2. Investigaciones antecedentes relacionadas con el tema
- 2.3. Base teórica - científica (teorías, modelos y conceptos científicos)
- 2.4. Definición de términos básicos

CAPÍTULO III: HIPÓTESIS Y VARIABLES (solo para el caso de investigaciones cuantitativas)

- 3.1. Supuestos básicos
- 3.2. Hipótesis general
- 3.3. Hipótesis específicas
- 3.4. Variables (definición operacional de variables: Dimensiones o indicadores)
- 3.5. Matriz de consistencia

CAPÍTULO IV: MARCO METODOLÓGICO

- 4.1. Tipo de investigación.
- 4.2. Método de investigación
- 4.3. Diseño del estudio.
- 4.4. Población y muestra (escenario de estudio)

- 4.5. Técnicas e instrumentos de recolección de datos (descripción, validez y confiabilidad)
- 4.6. Procedimiento de ejecución del estudio
- 4.7. Descripción del procedimiento para el procesamiento de datos.

CAPÍTULO V: RESULTADOS OBTENIDOS

- 5.1 Presentación de Datos Generales / socio demográfico.
- 5.2 Presentación de resultados y análisis de datos
- 5.3 Interpretación o discusión de resultados.

CAPÍTULO VI: CONCLUSIONES Y RECOMENDACIONES

- 6.1 Conclusiones Generales
- 6.2 Recomendaciones

Índice de tablas

Tabla 1: Matriz de operacionalización

Tabla 2: Matriz de consistencia

Tabla 3: Grilla hiper parámetros modelo SARIMA

Tabla 4: Grilla hiper parámetros modelo SARIMAX

Tabla 5: Grilla hiper parámetros modelo LSTM

Tabla 6: Resumen resultados de los experimentos

Índice de gráficos

Figura 1: Descomposición aditiva sku1

Figura 2: WMAPE simulación modelos SARIMA

Figura 3: WMAPE simulación modelos SARIMAX

Figura 4: WMAPE simulación modelos LSTM

RESUMEN

En el presente trabajo, el objetivo es desarrollar un modelo basado en técnicas de **inteligencia artificial** para mejorar la precisión del pronóstico de la demanda de aceites dentro de la cadena de suministro de una empresa de consumo masivo en Perú. Para ello, se combinaron y compararon modelos estadísticos clásicos como **SARIMA** y **SARIMAX** con técnicas avanzadas de aprendizaje profundo, específicamente una **red neuronal LSTM**. El modelo SARIMAX se utilizó para incorporar **variables exógenas** relevantes, como factores estacionales y externos, mientras que el LSTM permitió capturar **patrones no lineales y dependencias de largo plazo** en la serie temporal de ventas.

El estudio se basó en datos históricos de ventas mensuales de **48 productos de la categoría aceites**, abarcando el periodo de junio de 2021 a abril de 2025. Los resultados mostraron que el modelo **SARIMAX** logró la mayor precisión, alcanzando un **WMAPE mínimo de 0.0048** y una media de 0.49, superando a los modelos SARIMA y LSTM. El modelo **LSTM**, por su parte, mostró un buen desempeño con un WMAPE mínimo de 0.1718 y una media de 0.35, evidenciando su capacidad para capturar la complejidad de la demanda incluso ante fluctuaciones significativas. El modelo SARIMA, aunque con un WMAPE mínimo de 0.1501 y una media de 3.07, se posicionó como una alternativa sencilla y rápida de implementar en escenarios con clara estacionalidad.

El enfoque propuesto demostró superar en precisión a los métodos tradicionales como ARIMA y la suavización exponencial, validando la eficacia de integrar variables exógenas y técnicas de aprendizaje profundo para anticipar la demanda con mayor exactitud. Este esquema híbrido permite a la empresa optimizar la planificación de inventarios, reducir errores de forecast y mejorar la eficiencia operativa de la **cadena de suministro**, contribuyendo así a una toma de decisiones más robusta y adaptativa frente a la variabilidad del mercado.

Palabras clave: Forecast – Inteligencia Artificial – WMAPE – Consumo masivo

ABSTRACT

In this study, the objective is to develop a model based on artificial intelligence techniques to significantly improve the accuracy of demand forecasting for edible oils within the supply chain of a mass consumption company in Peru. To achieve this, classical statistical models such as SARIMA and SARIMAX were combined and compared with advanced deep learning techniques, specifically a Long Short-Term Memory (LSTM) neural network. The SARIMAX model was used to incorporate relevant exogenous variables, such as seasonal and external factors, while the LSTM network enabled the capture of non-linear patterns and long-term dependencies within the sales time series.

The study relied on historical monthly sales data for 48 oil products, covering the period from June 2021 to April 2025. The results showed that the SARIMAX model achieved the highest forecasting accuracy, reaching a minimum WMAPE of 0.0048 and an average of 0.49, outperforming both SARIMA and LSTM models. The LSTM model, meanwhile, demonstrated solid performance with a minimum WMAPE of 0.1718 and an average of 0.35, highlighting its ability to capture complex demand dynamics even under significant fluctuations. The SARIMA model, with a minimum WMAPE of 0.1501 and an average of 3.07, positioned itself as a simple and fast-to-implement option for scenarios with clear seasonality.

The proposed approach proved to outperform traditional methods such as ARIMA and exponential smoothing, validating the effectiveness of combining exogenous variables and deep learning to anticipate demand with greater accuracy. This hybrid scheme enables the company to optimize inventory planning, reduce forecast errors, and enhance the operational efficiency of the supply chain, thus contributing to more robust and adaptive decision-making in the face of market variability.

Keywords: Forecasting – Artificial Intelligence – WMAPE – Mass Consumption

CAPÍTULO I

1. Planteamiento del estudio

1.1. Descripción y delimitación del Problema

En el sector de consumo masivo, y particularmente en la comercialización de productos como los aceites comestibles, las empresas enfrentan desafíos constantes en la planificación de la demanda. Factores como la alta volatilidad del mercado, la estacionalidad, las promociones y los cambios abruptos en el comportamiento del consumidor dificultan la tarea de predecir con precisión la demanda futura. Estos desafíos generan riesgos significativos, tales como quiebres de stock, sobre inventario o ineficiencias logísticas que afectan directamente los costos operativos y la satisfacción del cliente.

Tradicionalmente, se han utilizado métodos estadísticos para abordar el problema del pronóstico de la demanda. Sin embargo, estas técnicas tienden a ser limitadas en su capacidad para capturar patrones no lineales y adaptarse a dinámicas complejas del mercado. En este contexto, la inteligencia artificial (IA) ha emergido como una alternativa prometedora para mejorar la precisión del forecasting. Gracias a su capacidad de aprendizaje y adaptación a grandes volúmenes de datos históricos, la IA permite modelar relaciones temporales complejas, identificar tendencias ocultas y anticipar comportamientos futuros con mayor exactitud que los métodos convencionales.

La aplicación de la IA en el pronóstico de la demanda no solo permite reducir errores de estimación, sino también incorporar variables exógenas relevantes, como eventos promocionales, tendencias estacionales o factores externos, los cuales son difíciles de integrar adecuadamente en modelos tradicionales. Esto resulta especialmente útil en categorías sensibles como los aceites, donde incluso pequeñas variaciones en la demanda pueden generar impactos logísticos y financieros significativos.

Este estudio se centra en la implementación de técnicas de inteligencia artificial para el pronóstico de la demanda de aceites en una empresa de consumo masivo. Se busca evaluar el desempeño de estas herramientas en comparación con los métodos tradicionales, determinar su capacidad de adaptación ante variabilidad de datos, y explorar su integración en los procesos actuales de planificación. Asimismo, se analizará el efecto de incorporar información exógena en los modelos predictivos, con el fin de optimizar la toma de decisiones en la cadena de suministro.

1.1.1. Formulación del problema (Problemática)

¿Cómo puede la empresa Alicorp mejorar la precisión de sus pronósticos de demanda de aceites utilizando técnicas de inteligencia artificial, frente a las limitaciones que presentan los métodos tradicionales ante la alta volatilidad y complejidad del mercado de consumo masivo?

1.1.2. Problema central del Estudio

◆ Precisión del pronóstico

¿En qué medida los métodos tradicionales de predicción limitan la precisión del forecast de la demanda al no capturar patrones no lineales ni adaptarse a cambios abruptos en el comportamiento de los consumidores?

◆ Uso de nuevas técnicas

¿Puede la implementación de técnicas de inteligencia artificial superar las limitaciones de los modelos estadísticos lineales, mejorando la capacidad de pronóstico ante comportamientos de consumo cada vez más complejos?

◆ Dinámica temporal

¿Cómo influye la naturaleza temporal, estacional y sujeta a eventos de la demanda en el sector de consumo masivo en la precisión de los modelos de predicción utilizados?

◆ Secuencialidad

¿De qué forma las técnicas de inteligencia artificial pueden aprovechar mejor la secuencia y evolución de los datos históricos para anticipar comportamientos futuros con mayor exactitud que los modelos tradicionales?

◆ Datos ruidosos y faltantes

¿Cómo afectan los datos ruidosos e incompletos a la capacidad predictiva de los modelos, y qué estrategias pueden emplearse para mitigar su impacto en el proceso de planificación de la demanda?

◆ Generalización

¿Son capaces los modelos de inteligencia artificial de generalizar adecuadamente su aprendizaje para mantener la precisión cuando se enfrentan a nuevos datos o situaciones no observadas?

◆ Interpretabilidad

¿Cómo puede abordarse el desafío de la interpretabilidad de los modelos de inteligencia artificial para garantizar que sus resultados sean comprensibles y útiles para los analistas comerciales y logísticos?

1.2. Objetivos de la Investigación

1.2.1. Objetivo general

Desarrollar un modelo basado en técnicas de inteligencia artificial que permita mejorar significativamente la precisión en el pronóstico de la demanda de aceites en una empresa de consumo masivo, superando las limitaciones de los métodos tradicionales y contribuyendo a una planificación más eficiente en la cadena de suministro.

1.2.2. Objetivos específicos

- a) Evaluar la eficacia de un modelo de inteligencia artificial en la predicción de la demanda de aceites, considerando la naturaleza secuencial y temporal de los datos históricos.
- b) Comparar el rendimiento del modelo de inteligencia artificial propuesto con técnicas de pronóstico tradicionales, utilizando métricas como WMAPE.
- c) Analizar el impacto de incorporar variables exógenas (como promociones, estacionalidad u otros factores externos) en la precisión del pronóstico generado por el modelo de inteligencia artificial.

1.3. Importancia del Estudio

◆ Optimización de la cadena de suministro

En las empresas de consumo masivo, una gestión eficiente de la cadena de suministro es clave para garantizar la disponibilidad de productos en el momento y lugar adecuados. La aplicación de técnicas de inteligencia artificial puede mejorar la precisión del pronóstico de demanda, permitiendo una mejor planificación de la producción, la distribución y la gestión de inventarios. Esto se traduce en decisiones más informadas, menores costos operativos y un aumento en la satisfacción del cliente.

◆ Reducción de excesos o faltantes de inventario

La inteligencia artificial permite identificar patrones de consumo con mayor precisión, lo cual ayuda a mantener un equilibrio adecuado entre oferta y demanda. De este modo, se pueden minimizar tanto los excesos de inventario (que generan sobrecostos logísticos) como los quiebres de stock (que reducen ventas y afectan la imagen de la marca).

◆ Adaptación a la volatilidad del mercado

El entorno comercial está en constante cambio debido a factores económicos, sociales y estacionales. Los métodos de IA, al ser capaces de capturar patrones no lineales y adaptarse rápidamente a nuevas condiciones, ofrecen

una herramienta valiosa para anticiparse a variaciones bruscas en la demanda y responder de manera ágil y eficiente.

◆ **Ventaja competitiva**

Las empresas que adoptan soluciones basadas en inteligencia artificial logran una ventaja frente a sus competidores al contar con herramientas más precisas para predecir la demanda y planificar sus operaciones. Esta ventaja se refleja en una mayor agilidad, menores niveles de desperdicio y una mejor capacidad de respuesta ante los cambios del mercado.

1.4. Justificación del Estudio (aporte, contribución)

◆ **Avance en la aplicación de inteligencia artificial en la cadena de suministro**

Este estudio contribuye al desarrollo del conocimiento sobre el uso de la inteligencia artificial en entornos logísticos, específicamente en el ámbito del pronóstico de demanda para productos de consumo masivo como los aceites. Al aplicar modelos de IA en contextos reales de planificación, se genera evidencia empírica sobre su efectividad, aportando valor tanto al campo académico como al industrial.

◆ **Superación de limitaciones de métodos tradicionales**

Los enfoques tradicionales de predicción, como ARIMA o los métodos de suavización exponencial, presentan limitaciones frente a patrones no lineales o cambios bruscos en la demanda. Este estudio propone el uso de modelos basados en IA como una alternativa más robusta y flexible, capaz de capturar relaciones complejas en los datos históricos. Así, se proporciona una solución moderna que responde mejor a los desafíos actuales de la planificación de la demanda.

◆ **Beneficios económicos y operativos**

Una predicción de demanda más precisa se traduce en una mejor planificación de inventarios, producción y distribución. Esto permite reducir los costos asociados al sobre stock o desabastecimiento, mejora la eficiencia operativa y fortalece la toma de decisiones en la cadena de suministro.

1.5. Delimitación del Estudio

◆ **Disponibilidad limitada de datos históricos**

El estudio se desarrolla considerando que la disponibilidad y calidad de los datos históricos de demanda pueden ser limitadas. Esta restricción influye en la

capacidad de los modelos de inteligencia artificial para aprender patrones representativos y afecta directamente la precisión del pronóstico.

◆ Complejidad computacional

La aplicación de técnicas de inteligencia artificial en el pronóstico de series temporales demanda una infraestructura computacional adecuada. El entrenamiento de los modelos y la generación de predicciones requieren recursos considerables, lo cual implica una delimitación en términos de tiempo de procesamiento y capacidad técnica disponible para su ejecución.

◆ Generalización a datos futuros

El modelo desarrollado será evaluado no solo por su desempeño en los datos históricos, sino también por su capacidad de generalizar a escenarios futuros. Esta capacidad de generalización es esencial para su utilidad práctica en el contexto dinámico del mercado de aceites, aunque presenta limitaciones inherentes a los cambios no observados en los datos de entrenamiento.

◆ Sensibilidad a hiperparámetros

El modelo de inteligencia artificial utilizado posee múltiples hiperparámetros que deben ser cuidadosamente ajustados para optimizar su rendimiento. El proceso de calibración representa una delimitación metodológica relevante, dado que influye directamente en la estabilidad y precisión del modelo.

◆ Interpretación y explicabilidad del modelo

Dado que los modelos basados en inteligencia artificial son considerados "cajas negras", una de las limitaciones del estudio es la dificultad para interpretar cómo se generan las predicciones. Esto puede representar un reto en entornos donde se requiere transparencia para la toma de decisiones estratégicas en la cadena de suministro.

◆ Escalabilidad y aplicabilidad industrial

La investigación se enfoca en un caso específico dentro del sector de consumo masivo. Aunque se busca que el modelo sea replicable, su escalabilidad e integración en sistemas reales de planificación dependerá de factores técnicos, organizacionales y económicos propios de la empresa.

◆ Limitaciones en la predicción a largo plazo

El estudio está orientado principalmente a mejorar los pronósticos en el corto y mediano plazo. Si bien se explora la capacidad de la IA para anticipar comportamientos futuros, existen limitaciones naturales en la predicción a largo plazo, especialmente ante eventos exógenos o disruptivos no contenidos en los datos históricos.

CAPITULO II

2. MARCO TEÓRICO:

2.1. Marco Histórico:

Historia y Actividades de Alicorp S.A.A.

Alicorp S.A.A., fundada en 1956, es una de las empresas líderes en el sector de consumo masivo en el Perú, dedicada a la producción y comercialización de productos de consumo masivo, alimentos, cuidado personal, y soluciones industriales. Con sede en Lima, Alicorp ha evolucionado a lo largo de los años desde una pequeña empresa de aceites y detergentes hasta convertirse en una multinacional que opera en más de 20 países en América Latina. La diversificación de sus productos y la expansión hacia mercados internacionales ha permitido a Alicorp posicionarse como un actor clave en la industria, impulsando la innovación y el desarrollo sostenible en la región (Alicorp, 2023).

Dentro de su portafolio, Alicorp maneja marcas reconocidas que abarcan desde alimentos hasta productos de limpieza, siendo uno de los principales proveedores para cadenas de supermercados, mayoristas y minoristas. Además de su enfoque en el consumidor, la empresa también ofrece soluciones industriales y productos dirigidos a otras compañías de la industria alimentaria y agrícola. Su compromiso con la calidad y la mejora continua ha permitido a la empresa mantenerse competitiva en un mercado dinámico y en constante evolución, enfrentando desafíos como la volatilidad de la demanda y las fluctuaciones en las condiciones del mercado global.

Demand Planning

Es un proceso estratégico y colaborativo de la gestión de la cadena de suministro que combina el análisis de datos históricos, tendencias del mercado y factores externos para proyectar la demanda futura y organizar eficientemente las actividades de abastecimiento, producción y distribución. Su propósito es mantener un equilibrio óptimo entre la capacidad de suministro y la oportunidad del mercado, evitando tanto el exceso de inventario como el desabastecimiento.

Según NetSuite, integra pronósticos de ventas, gestión de inventarios y planificación de producción, utilizando datos internos y externos para ajustar los niveles de stock y satisfacer la demanda del cliente de forma eficiente.

Además, se menciona que es un proceso continuo y multifuncional, esencial para mejorar la eficiencia operativa, reducir costos e incrementar la satisfacción del cliente.

Forecasting:

El **forecasting** o pronóstico de demanda ha evolucionado significativamente desde sus inicios en las primeras prácticas comerciales hasta convertirse en un campo esencial en la planificación de la cadena de suministro y la gestión empresarial.

Orígenes del Forecasting

El pronóstico de demanda comenzó con métodos simples basados en observaciones empíricas y promedios históricos. Durante la Revolución Industrial (siglo XIX), la necesidad de predecir la demanda de materias primas y productos manufacturados llevó al desarrollo de técnicas sistemáticas que incorporaban datos estadísticos y patrones de producción.

Desarrollo de Métodos Estadísticos (Siglo XX)

En el siglo XX, la introducción de técnicas estadísticas marcó un hito importante en el forecasting. Entre los métodos más destacados se encuentran:

- **Promedios móviles y suavización exponencial** (décadas de 1920-1940), utilizados para capturar tendencias y patrones estacionales.
- **Modelos ARIMA** (1970), desarrollados por George Box y Gwilym Jenkins, que integran componentes autorregresivos y de media móvil, ofreciendo un marco más robusto para analizar series temporales.

Incorporación de Tecnología (Finales del Siglo XX)

Con el auge de las computadoras, los métodos tradicionales se automatizaron y comenzaron a integrarse en herramientas de software empresarial, como los sistemas ERP. Esto permitió a las empresas manejar grandes volúmenes de datos históricos y mejorar la precisión de sus pronósticos.

Avances en Modelos Basados en Aprendizaje Automático (Siglo XXI)

En el siglo XXI, la aparición del **big data** y el avance en técnicas de inteligencia artificial revolucionaron el forecasting. Entre los principales avances destacan:

- **Redes Neuronales Artificiales (ANN)**: Introducción de modelos no lineales capaces de capturar relaciones complejas en los datos.
- **Redes Neuronales Recurrentes (RNN)** y variantes como LSTM y GRU: Estas técnicas, desarrolladas en la década de 1990 y popularizadas en los 2010, permiten modelar dependencias a largo plazo en series temporales.
- **Modelos híbridos**: Combinación de métodos estadísticos y de aprendizaje profundo para mejorar la robustez de los pronósticos.

Estado Actual y Futuro

Hoy en día, el forecasting integra datos en tiempo real y herramientas avanzadas de visualización para adaptarse a la volatilidad del mercado. Modelos como los de aprendizaje profundo y técnicas bayesianas están emergiendo como soluciones clave en entornos dinámicos y globalizados.

Este desarrollo histórico evidencia cómo el forecasting ha pasado de ser un proceso basado en intuición y métodos simples a una disciplina altamente técnica y automatizada, desempeñando un rol crucial en la planificación estratégica de empresas.

Introducción general al pronóstico en la cadena de suministro

El pronóstico de la demanda constituye una función crítica en la gestión de la cadena de suministro, especialmente en el sector de consumo masivo, donde las empresas deben anticipar la demanda futura para tomar decisiones estratégicas sobre producción, inventarios y distribución. En productos como aceites comestibles, caracterizados por patrones estacionales, promociones y fluctuaciones en el consumo, la precisión en el pronóstico es esencial para evitar quiebres de stock o sobre inventarios. Tradicionalmente, se han utilizado modelos estadísticos como ARIMA, SARIMA y modelos de suavizamiento exponencial. Si bien estos métodos han ofrecido resultados aceptables en contextos estables, presentan limitaciones importantes ante patrones no lineales y dinámicas de mercado impredecibles.

Modelos tradicionales de pronóstico

Los modelos estadísticos convencionales, como los autorregresivos (AR) y los modelos de media móvil integrada autorregresiva estacional (SARIMA), han sido ampliamente utilizados para pronosticar series temporales en entornos industriales y comerciales. Estos modelos se basan en la dependencia lineal entre observaciones pasadas y actuales, y suelen ser eficaces en contextos con patrones estacionales o cíclicos claros. No obstante, estudios como los de Kumar et al. (2023) y Vien et al. (2021) han evidenciado que estos modelos son poco eficaces para capturar dinámicas complejas, dependencias no lineales y cambios abruptos en la demanda, condiciones cada vez más frecuentes en mercados volátiles como el de productos de consumo masivo.

Introducción a la inteligencia artificial en el pronóstico de la demanda

Ante las limitaciones de los métodos tradicionales, la **inteligencia artificial (IA)** ha emergido como una herramienta poderosa para mejorar la capacidad predictiva en entornos de alta incertidumbre. En particular, los modelos basados en redes neuronales permiten identificar patrones complejos y relaciones no lineales en grandes volúmenes de datos históricos. Las redes neuronales recurrentes (RNN) y sus variantes como LSTM (Long Short-Term Memory) y GRU (Gated Recurrent Unit) han demostrado ser especialmente efectivas para modelar datos secuenciales, como las series de demanda.

Inteligencia artificial y su aplicación al forecasting

1. Redes neuronales artificiales (ANN)

Las redes neuronales artificiales imitan el funcionamiento del cerebro humano a través de capas de nodos interconectados, denominados neuronas. En aplicaciones de pronóstico, las ANN tradicionales (como el Perceptrón Multicapa) se han utilizado para capturar patrones en datos históricos, con resultados satisfactorios en problemas simples o bien estructurados (Pakbin et al., 2024).

2. Redes neuronales recurrentes (RNN)

Las RNN introducen conexiones temporales entre sus nodos, permitiendo mantener una “memoria” de estados anteriores. Esta característica las hace especialmente útiles en el modelado de series temporales. Sin embargo, presentan problemas al capturar dependencias a largo plazo debido al fenómeno del desvanecimiento del gradiente (Zhao et al., 2020).

3. Long Short-Term Memory (LSTM)

Las LSTM fueron desarrolladas por Hochreiter y Schmidhuber (1997) para superar las limitaciones de las RNN. Incorporan mecanismos de puertas que permiten retener, olvidar o actualizar información a lo largo del tiempo. Estas redes han demostrado un excelente desempeño en aplicaciones de consumo masivo por su capacidad para anticipar patrones complejos y adaptarse a datos ruidosos o no estacionarios (Zargar, 2021; Guo & Lin, 2018).

4. Gated Recurrent Unit (GRU)

Las GRU son una simplificación de las LSTM que reducen la complejidad computacional manteniendo un rendimiento competitivo. Su estructura con dos puertas (de actualización y reinicio) permite modelar secuencias temporales de forma eficiente, siendo útiles en contextos donde los recursos de procesamiento son limitados.

Incorporación de variables exógenas

La demanda de productos de consumo masivo como aceites está fuertemente influenciada por factores externos: campañas promocionales, clima, eventos sociales, entre otros. La integración de **variables exógenas** en modelos predictivos mejora significativamente la precisión de los pronósticos (Guo & Lin, 2018; Orunkara Poyil, 2019). Modelos multivariados basados en IA permiten incorporar este tipo de información de manera efectiva, facilitando una planificación más alineada con la realidad del mercado.

Comparación entre modelos tradicionales y basados en IA

Diversos estudios han demostrado que los modelos de inteligencia artificial, en particular los basados en LSTM, superan a los métodos tradicionales en precisión de pronóstico. El Filali et al. (2022) y Nguyen et al. (2020) encontraron que los modelos LSTM optimizados ofrecían menor error (RMSE y MAE) que ARIMA y otros métodos estadísticos, incluso en condiciones de alta volatilidad. En entornos como el de Alicorp, donde se manejan múltiples referencias y mercados, esta mejora en precisión se traduce en beneficios operativos tangibles, como reducción de inventarios, mejor servicio al cliente y mayor eficiencia logística.

Avances recientes y modelos híbridos

El desarrollo de modelos híbridos que combinan técnicas tradicionales y de IA representa un avance importante. Boyang Li et al. (2024) propusieron el modelo DeepLDF, que combina SARIMA con redes neuronales convolucionales, logrando mejores resultados que los modelos individuales. También se destacan trabajos como el de Babai et al. (2022) sobre reconciliación jerárquica, y el de Stranieri et al. (2024) que integra aprendizaje por refuerzo profundo con programación estocástica para planificación de inventarios.

Aplicabilidad práctica y desafíos

Si bien los modelos basados en IA ofrecen importantes ventajas, su adopción presenta desafíos:

- **Disponibilidad y calidad de datos históricos**
- **Requerimientos computacionales y de infraestructura**
- **Dificultades de interpretabilidad y validación**
- **Escalabilidad a nivel industrial**

Estudios como los de Feizabadi (2022), Douaioui (2024) y Khedr (2024) coinciden en que los beneficios superan las barreras si se cuenta con una adecuada integración de los modelos en los sistemas de planificación existentes y una estrategia clara para su interpretación y mantenimiento.

WMAPE (Error de Porcentaje Absoluto Medio Ponderado): El WMAPE es una variante del MAPE que pondera los errores porcentuales absolutos según la demanda. Es especialmente útil cuando se trabaja con productos o servicios con diferentes niveles de demanda.

Fórmula:

$$WMAPE = \frac{\sum_{i=1}^n |F_i - D_i|}{\sum_{i=1}^n D_i} \times 100\%$$

2.4. Definición de términos básicos:

- **Serie temporal:** Secuencia de datos recolectados a lo largo del tiempo, usualmente en intervalos regulares. En este estudio, representa las ventas mensuales de productos.
- **Descomposición aditiva:** Técnica que separa una serie temporal en tres componentes: tendencia, estacionalidad y ruido, asumiendo que la serie es la suma de estos.
- **Estacionalidad:** Componente repetitivo o cíclico que ocurre en intervalos regulares, como trimestres o estaciones del año, y afecta los patrones de la serie temporal.
- **SARIMA (Seasonal Autoregressive Integrated Moving Average):** Modelo estadístico que extiende el modelo ARIMA para incluir estacionalidad, permitiendo capturar tanto patrones regulares como estacionales en series temporales. Se expresa como SARIMA(p,d,q)(P,D,Q,s).
- **SARIMAX (SARIMA with exogenous variables):** Extensión del modelo SARIMA que incluye variables exógenas (factores externos) para mejorar la precisión del pronóstico.
- **LSTM (Long Short-Term Memory):** Tipo de red neuronal recurrente (RNN) diseñada para aprender secuencias y dependencias a largo plazo. Se utiliza para modelar patrones temporales complejos en series de datos.
- **Ventana temporal (Window size):** Número de observaciones pasadas utilizadas como entrada en modelos secuenciales como LSTM para predecir valores futuros.
- **Época (Epoch):** Una pasada completa por el conjunto de entrenamiento durante el proceso de entrenamiento de una red neuronal.
- **Función de activación:** Función matemática utilizada en redes neuronales para introducir no linealidades. En este estudio, se utiliza tanh, que transforma los datos a un rango entre -1 y 1.
- **Optimizador:** Algoritmo que ajusta los pesos del modelo para minimizar el error de predicción. En este estudio se utilizan adam y rmsprop.
- **WMAPE (Weighted Mean Absolute Percentage Error):** Métrica de evaluación que mide el error porcentual absoluto medio ponderado, útil para comparar precisión entre modelos de predicción de demanda.
- **AIC (Akaike Information Criterion) y BIC (Bayesian Information Criterion):** Criterios de selección de modelos que penalizan la complejidad del modelo. Un menor valor de AIC o BIC indica un modelo más eficiente.

- **Rolling Window:** Técnica que implica mover una ventana de tiempo fija a lo largo de la serie para entrenar y evaluar modelos de forma iterativa, útil para validar la robustez de los pronósticos.
- **Modelo parsimonioso:** Modelo que logra un buen ajuste a los datos con la menor cantidad de parámetros posible, evitando el sobreajuste.

CAPÍTULO III

3. HIPOTESIS Y VARIABLES

3.1. SUPUESTOS BASICOS

Estos supuestos son fundamentales para asegurar la viabilidad y validez de la aplicación de inteligencia artificial en el pronóstico de la demanda dentro de una empresa de consumo masivo:

3.1.1. Disponibilidad y Calidad de los Datos

Se cuenta con un conjunto de datos históricos de demanda de alta calidad, que incluye variables relevantes y completas para la predicción.

- **Justificación:** La precisión del modelo de inteligencia artificial depende directamente de la calidad y cantidad de datos históricos disponibles. Los datos deben contener información suficiente sobre la demanda histórica, incluyendo variables como volumen de ventas, fechas, promociones, entre otros.
- **Fuente de datos:** La información proviene de sistemas de gestión de inventario y bases de datos operacionales de la empresa.

3.1.2. Representatividad de la Muestra

Los datos utilizados son representativos del comportamiento general de la demanda de la empresa de consumo masivo.

- **Justificación:** Para que los resultados obtenidos del modelo sean aplicables a futuras predicciones, los datos utilizados deben reflejar adecuadamente la diversidad y variabilidad de los patrones de demanda en diferentes épocas del año y segmentos de productos.

3.1.3. Estabilidad de los Patrones de Demanda

Se asume que los patrones de demanda históricos son estables y pueden ser utilizados para predecir futuros comportamientos.

- **Justificación:** Las técnicas de pronóstico se basan en la identificación de patrones en datos secuenciales. Si los patrones de demanda cambian drásticamente debido a factores externos, el rendimiento del modelo puede verse afectado.
- **Consideraciones:** El análisis de series temporales ayudará a monitorear la estabilidad de los patrones y ajustar el modelo en consecuencia.

3.1.4. Influencia de Variables Exógenas

Las variables externas, como eventos promocionales, días festivos, o condiciones macroeconómicas, pueden ser incorporadas y tienen un impacto predecible en la demanda.

- **Justificación:** Las técnicas de inteligencia artificial puede mejorar su precisión si se integran variables externas que influyen en la demanda. Se asume que estas variables se pueden medir y modelar adecuadamente.
- **Variables externas:** Festividades, eventos de marketing, variaciones económicas, entre otros.

3.1.5. Disponibilidad de Recursos Computacionales

La empresa cuenta con los recursos computacionales necesarios para procesar grandes volúmenes de datos y ejecutar modelos de redes neuronales complejos.

- **Justificación:** Los modelos de inteligencia artificial, especialmente aquellas variantes como las redes neuronales, requieren un alto poder computacional para entrenar y ejecutar los modelos con precisión.
- **Infraestructura:** Se dispone de hardware adecuado (servidores o infraestructura en la nube), software especializado (como TensorFlow o Keras), y personal capacitado para gestionar el proceso de modelado.

3.1.6. Hiperparámetros del Modelo Ajustables

Los hiperparámetros de las técnicas de inteligencia artificial pueden ser ajustados de manera óptima mediante validación cruzada o técnicas similares.

- **Justificación:** La correcta configuración de los hiperparámetros es crucial para obtener un rendimiento adecuado.

3.2. HIPOTESIS GENERAL

La implementación de pronósticos con inteligencia artificial mejora significativamente la precisión del pronóstico de la demanda en comparación con los métodos tradicionales de predicción en una empresa de consumo masivo.

3.3. HIPOTESIS ESPECIFICAS

- El uso de inteligencia artificial en la predicción de la demanda supera en precisión a los modelos tradicionales como ARIMA y la suavización exponencial.

- La incorporación de variables exógenas en el modelo de inteligencia artificial mejora la precisión del pronóstico en comparación con un modelo basado únicamente en datos históricos.
- Los modelos de inteligencia artificial son capaces de adaptarse a las fluctuaciones y variabilidad del mercado, reduciendo el error en el pronóstico de la demanda en comparación con los métodos estadísticos tradicionales.
- La integración del modelo de inteligencia artificial en los sistemas de planificación existentes en la empresa de consumo masivo es viable y escalable, lo que contribuye a una mejor toma de decisiones en la cadena de suministro.

3.4. VARIABLES (DEFINICIÓN OPERACIONAL DE VARIABLES: DIMENSIONES O INDICADORES)

Variables Independientes

- **Datos Históricos de Demanda:** La secuencia de ventas pasadas que sirve como entrada principal para el modelo de pronóstico.
 - **Indicadores:** Volumen de ventas diarias/mensuales, estacionalidad, tendencias, patrones de compra anteriores.
- **Variables Exógenas:** Factores externos que afectan la demanda.
 - **Indicadores:** Días festivos, promociones, campañas de marketing, condiciones económicas, clima.
- **Preprocesamiento de Datos:** Técnicas aplicadas para limpiar y preparar los datos antes de ingresarlos al modelo.
 - **Indicadores:** Métodos de imputación de datos faltantes, normalización, eliminación de outliers.
- **Hiperparámetros del Modelo:** Parámetros ajustables que controlan el rendimiento del modelo.
 - **Indicadores:** Número de épocas, tamaño del batch, número de unidades de memoria, regularización (dropout).

Variables Dependientes

- **Precisión del Pronóstico de la Demanda:** Nivel de exactitud en las predicciones de demanda realizadas por el modelo RNN.
 - **Indicadores:** error porcentual absoluto medio ponderado (WMAPE).

Tabla 1: Matriz de operacionalización

Variable	Indicador	Definición conceptual	Definición operacional	Dimensiones	Instrumento
Variables independientes					
Datos Históricos de Demanda	Volumen de ventas diarias/mensuales, estacionalidad, tendencias, patrones de compra anteriores	Secuencia cronológica de registros de ventas que constituye la base para el pronóstico de la demanda	Datos de ventas recolectados mes a mes para cada SKU, organizados como series temporales para alimentar los modelos de forecasting	Volumen de ventas Estacionalidad Tendencia histórica	Base de datos interna de ventas
Preprocesamiento de Datos	Imputación de datos faltantes, normalización, eliminación de outliers	Conjunto de métodos utilizados para preparar y limpiar los datos antes de ser procesados por el modelo	Técnicas de limpieza y transformación aplicadas a la base de ventas y variables exógenas para asegurar la calidad de la entrada al modelo	Imputación de valores	Scripts de limpieza de datos,
Hiperparámetros del Modelo	Número de épocas, tamaño del batch, número de unidades LSTM, regularización (dropout)	Parámetros ajustables que definen la arquitectura y el rendimiento de la red neuronal	Valores numéricos configurados durante la fase de entrenamiento del modelo para optimizar su desempeño	Configuración de red neuronal Rendimiento del entrenamiento	Documentación del modelo, registros de configuración de entrenamiento
Variable dependiente					
Precisión del Pronóstico de la Demanda	WMAPE (Weighted Mean Absolute Percentage Error)	Nivel de exactitud alcanzado por el modelo para predecir la demanda futura	Medición del error porcentual absoluto ponderado obtenido al comparar la predicción del modelo con la demanda real observada	Error de predicción	Reportes de evaluación de modelos, métricas calculadas automáticamente

Fuente: Elaboración Propia

Tabla 2: Matriz de consistencia

Problemas Específicos	Objetivos Específicos	Hipótesis Específicas	Variables Independientes	Variables Dependientes	Método de Medición	Instrumento
PE1: ¿Cómo mejoran las técnicas de inteligencia artificial en el pronóstico de la demanda en comparación con los métodos tradicionales?	OE1: Evaluar la efectividad de las técnicas de inteligencia artificial a en el pronóstico de la demanda frente a métodos tradicionales como ARIMA.	H1: Las técnicas de inteligencia artificial a mejoran la precisión del pronóstico de la demanda en comparación con los métodos tradicionales.	HISTORICO DE VENTAS HORIZONTE NATURALEZA DEL PRODUCTO	Pronóstico de Demanda	WMAPE	Herramientas de análisis (Python, TensorFlow, Keras)

PE2: ¿Cómo influye la inclusión de variables exógenas en el rendimiento del modelo de IA para el pronóstico de demanda?	OE2: Explorar el impacto de variables exógenas en la mejora del pronóstico de la demanda mediante IA.	H2: La inclusión de variables exógenas en el modelo de IA mejora la precisión del pronóstico de demanda.	Variables Exógenas (Promociones, Festividades, Condiciones Económicas)	Pronóstico de Demanda	Análisis de precisión con y sin variables exógenas (MAE, WMAPE)	Herramientas de análisis de series temporales (Python, R)
PE3: ¿Qué impacto tiene la implementación de IA en la optimización de inventarios?	OE3: Analizar cómo las IA impactan en la optimización del inventario.	H3: La implementación de RNN reduce los costos operativos y optimiza la gestión de inventarios.	Redes Neuronales Recurrentes (RNN),	Optimización de Inventarios,	Reducción de los Días Giro	

Fuente: Elaboración propia

CAPÍTULO IV

4. Marco metodológico

4.1. Tipo de investigación:

- Enfoque: La investigación es de enfoque **cuantitativo**, ya que se centrará en la recolección y análisis de datos numéricos relacionados con los patrones históricos de la demanda, utilizando herramientas de inteligencia artificial y técnicas estadísticas para medir la precisión de los pronósticos. Además, se prioriza la evaluación objetiva de las métricas de error como WMAPE.
- Nivel: El nivel de la investigación es **aplicado**, ya que tiene como objetivo utilizar las técnicas de inteligencia artificial para resolver un problema práctico: mejorar la precisión de los pronósticos de demanda en una empresa de consumo masivo (Alicorp). El conocimiento generado se orienta directamente a optimizar la planificación y operación en la cadena de suministro.

4.1. Método

El método es **analítico**, ya que la investigación descompondrá la información en sus componentes esenciales (como tendencias, estacionalidad y ruido en las series temporales) para evaluar el comportamiento de la demanda y las mejoras logradas con el modelo propuesto. Este enfoque también incluye el análisis comparativo con métodos tradicionales como ARIMA y SARIMA.

4.2. Diseño:

El diseño es **longitudinal**, ya que el análisis se realizará sobre datos históricos de demanda recopilados a lo largo del tiempo (desde 2021 hasta 2025) y evaluará la evolución de los patrones temporales para generar predicciones en horizontes futuros. Esto implica un seguimiento sistemático de las variables de interés en el tiempo.

4.3. Población y Muestra:

Población:

La población de la investigación comprende **los datos históricos de demanda** de los productos de aceites de la empresa Alicorp. Estos datos incluyen:

- **Registros mensuales de ventas** entre enero de 2021 y abril de 2025.
- Variables relacionadas como estacionalidad de las ventas históricas, y otros factores que influyen en la demanda.

Este universo representa el escenario completo sobre el cual se busca aplicar y validar los modelos de inteligencia artificial para la predicción de demanda.

Muestra:

La muestra seleccionada incluye:

- **Productos clave** o de alto impacto en términos de ingresos para la empresa.
- Un subconjunto representativo de los aceites principales, considerando:
 - Disponibilidad de datos históricos completos y confiables.

Criterios de Selección de la Muestra:

1. Productos con al menos 36 meses de datos históricos para garantizar que la serie temporal sea suficientemente robusta.
2. Variabilidad en el comportamiento de demanda (picos estacionales, tendencia creciente/decadente).

4.4. Técnicas e instrumentos de recolección de datos:

Técnicas de Recolección de Datos

Se utilizarán técnicas cuantitativas para recopilar datos históricos relacionados con la demanda y otros factores que influyen en su comportamiento. Las principales técnicas son:

1. Análisis de Registros Históricos:

- Se extraerán datos de los sistemas de información de Alicorp (como sistemas ERP o plataformas de gestión de inventarios) que incluyen:
 - Volumen de ventas mensual por producto.
 - Duración y frecuencia de promociones.
 - Descuentos aplicados.

2. Consulta a Fuentes Secundarias:

- Incorporación de datos de mercado provenientes de estudios sectoriales o bases de datos de mercado para enriquecer el análisis, como tendencias de consumo y comportamiento del mercado en diferentes temporadas.

3. **Análisis de Bases de Datos Internas:**

- Uso de bases históricas relacionadas con promociones, precios, y estacionalidades de ventas para identificar patrones y complementar el modelado de la demanda.

Instrumentos de Recolección de Datos

1. **Plataforma de Gestión de Datos:**

- **ERP de Alicorp:** Sistema de planificación de recursos empresariales para la extracción de datos históricos estructurados.
- **Bases de Datos Relacionales:** Herramientas como MySQL o Excel para organizar los datos extraídos.

2. **Herramientas de Software:**

- **Python:** Uso de bibliotecas como pandas, numpy, y sqlalchemy para acceder, procesar, y estructurar los datos recopilados.
- **Google Analytics o Similar:** Para extraer información adicional relacionada con tendencias de mercado, si aplica.

3. **Validación y Calidad de Datos:**

- Se emplearán técnicas de validación para garantizar que los datos sean consistentes y libres de errores. Esto incluye la eliminación de valores atípicos y el manejo de datos faltantes mediante imputación.

Validez y Confiabilidad de los Datos

• **Validez:**

- Los datos utilizados provienen de registros oficiales de la empresa y estudios confiables, asegurando que reflejan la realidad operativa y del mercado.

• **Confiabilidad:**

- Uso de métricas estadísticas (como correlación y análisis de tendencia) para verificar que los datos son consistentes y se ajustan a los patrones esperados en series temporales.

4.5. Descripción y procedimiento de análisis:

Descripción del Procedimiento

El análisis comparativo de los modelos de pronóstico se realizará empleando un enfoque de **rolling window** para evaluar el rendimiento de los métodos en términos de precisión. Los modelos seleccionados para el estudio son:

1. **SARIMAX (Seasonal ARIMA).**
2. **Red Neuronal Recurrente LSTM.**
3. **Autoencoder**
4. **Programación estocástica multietapa**

El principal criterio de evaluación será el cálculo iterativo del **WMAPE (Weighted Mean Absolute Percentage Error)** en cada ventana del rolling window.

Procedimiento de Análisis

1. Preparación de los Datos:

- Los datos históricos de demanda se dividen en:
 - **Periodo de Entrenamiento Inicial:** Los primeros meses para ajustar los modelos (por ejemplo, 24 meses).
 - **Periodo de Validación/Backtesting:** Los meses restantes para validar y comparar las predicciones.
- Las ventanas se expanden iterativamente agregando nuevos datos al conjunto de entrenamiento y evaluando el modelo en datos futuros.

2. Implementación del Rolling Window:

- Se utilizará una ventana de tiempo inicial fija y, en cada iteración:
 - La ventana de entrenamiento se expande para incluir un nuevo periodo.
 - Se recalculan las predicciones sobre el siguiente periodo de validación.
- Este procedimiento asegura que los modelos aprovechen la información histórica acumulativa en cada iteración.

3. Criterios de Evaluación:

- En cada iteración se calculará el **WMAPE** para comparar la precisión de los modelos

4. Comparación de Modelos:

- Se generará un ranking basado en el promedio del **WMAPE** para todas las iteraciones.
- El modelo con el menor **WMAPE** promedio será seleccionado como el más preciso para las condiciones del estudio.

CAPÍTULO V

1.1. Presentación de datos generales

En este estudio, se utilizó una base de datos interna de la empresa, compuesta por registros históricos de ventas de **48 productos de la categoría aceites**, correspondientes al periodo comprendido entre **junio de 2021 y abril de 2025**. Esta base fue seleccionada por su relevancia directa con la planificación de la demanda y su consistencia en términos de cobertura temporal y detalle de producto, lo que permite desarrollar modelos de predicción con mayor fiabilidad.

Para cada producto se realizó un **análisis exploratorio** mediante técnicas de **descomposición aditiva**, con el fin de identificar tendencias, estacionalidades y fluctuaciones específicas a lo largo del tiempo. En la **Figura 1**, se muestra un ejemplo de esta descomposición para uno de los SKU analizados, donde se observa un **incremento pronunciado en las ventas** durante el periodo de **julio de 2021 a junio de 2022**, así como un patrón **estacional marcado**, evidenciando picos de ventas durante el cuarto trimestre de cada año y valles durante el primero.

Para facilitar el procesamiento y garantizar la integridad de la información, los datos fueron exportados en formato **CSV**, lo que permite una manipulación más eficiente y replicable. Posteriormente, se verificó la coherencia de los registros, asegurando la correspondencia con el periodo definido y la completitud de los datos. Esta verificación incluyó la revisión de formatos, rangos de fechas, detección de inconsistencias y valores atípicos.

El **preprocesamiento** contempló tareas de **limpieza de duplicados**, tratamiento de **valores faltantes** mediante técnicas de imputación y **escalado de variables** mediante normalización Min-Max, mejorando así la comparabilidad de los valores dentro de los modelos de pronóstico. Para este proceso, se utilizaron herramientas y librerías de **Python**, como **Pandas** y **NumPy**, garantizando una gestión eficiente y estructurada de la información para su posterior modelado.




Figura 1: Descomposición aditiva sku1

1.2. Presentación de resultados y análisis de datos

En esta sección se presenta una **comparativa de modelos estadísticos y de inteligencia artificial** aplicados al pronóstico de la demanda de aceites en una empresa de consumo masivo. Los datos históricos utilizados provienen de la base interna de ventas de la compañía, y abarcan el periodo comprendido entre **junio de 2021 y abril de 2025**, cubriendo un total de **48 productos** de la categoría aceites.

La comparación entre modelos permitirá identificar la técnica de predicción más precisa y eficiente, proporcionando una herramienta práctica para optimizar la planificación de la demanda, mejorar la gestión de inventarios y fortalecer la toma de decisiones dentro de la cadena de suministro.

A continuación, se presentan los experimentos realizados con **tres enfoques de modelado**: el modelo estadístico **SARIMA**, el modelo extendido **SARIMAX** con variables exógenas, y la **red neuronal LSTM**, técnica de aprendizaje profundo capaz de capturar dependencias no lineales y de largo plazo.

SARIMA

Para las simulaciones del algoritmo SARIMA se consideraron el siguiente universo de posibles hiper parámetros:

Parámetro	Descripción	Valores evaluados
p	Orden autorregresivo (AR): número de rezagos incluidos para explicar la serie.	0, 1, 2
d	Diferenciación (I): número de diferenciaciones aplicadas para hacer la serie estacionaria.	0, 1, 2
q	Orden de media móvil (MA): número de términos de error rezagados incluidos en el modelo.	0, 1, 2
P	Orden autorregresivo estacional (SAR): rezagos estacionales que explican la estacionalidad.	0, 1, 2
D	Diferenciación estacional (SI): diferenciaciones aplicadas para eliminar la estacionalidad.	0, 1, 2
Q	Orden de media móvil estacional (SMA): términos de error rezagados para modelar estacionalidad.	0, 1, 2
s	Periodicidad estacional (S): longitud del ciclo estacional en la serie temporal.	12 (mensualidad)
Combinaciones totales	Número total de combinaciones simuladas en la grilla de búsqueda.	27 (ARIMA) × 27 (Estacional) = 729 configuraciones

Tabla 3: Grilla hiper parámetros modelo SARIMA

Fuente: Elaboración propia

Con los siguientes resultados:

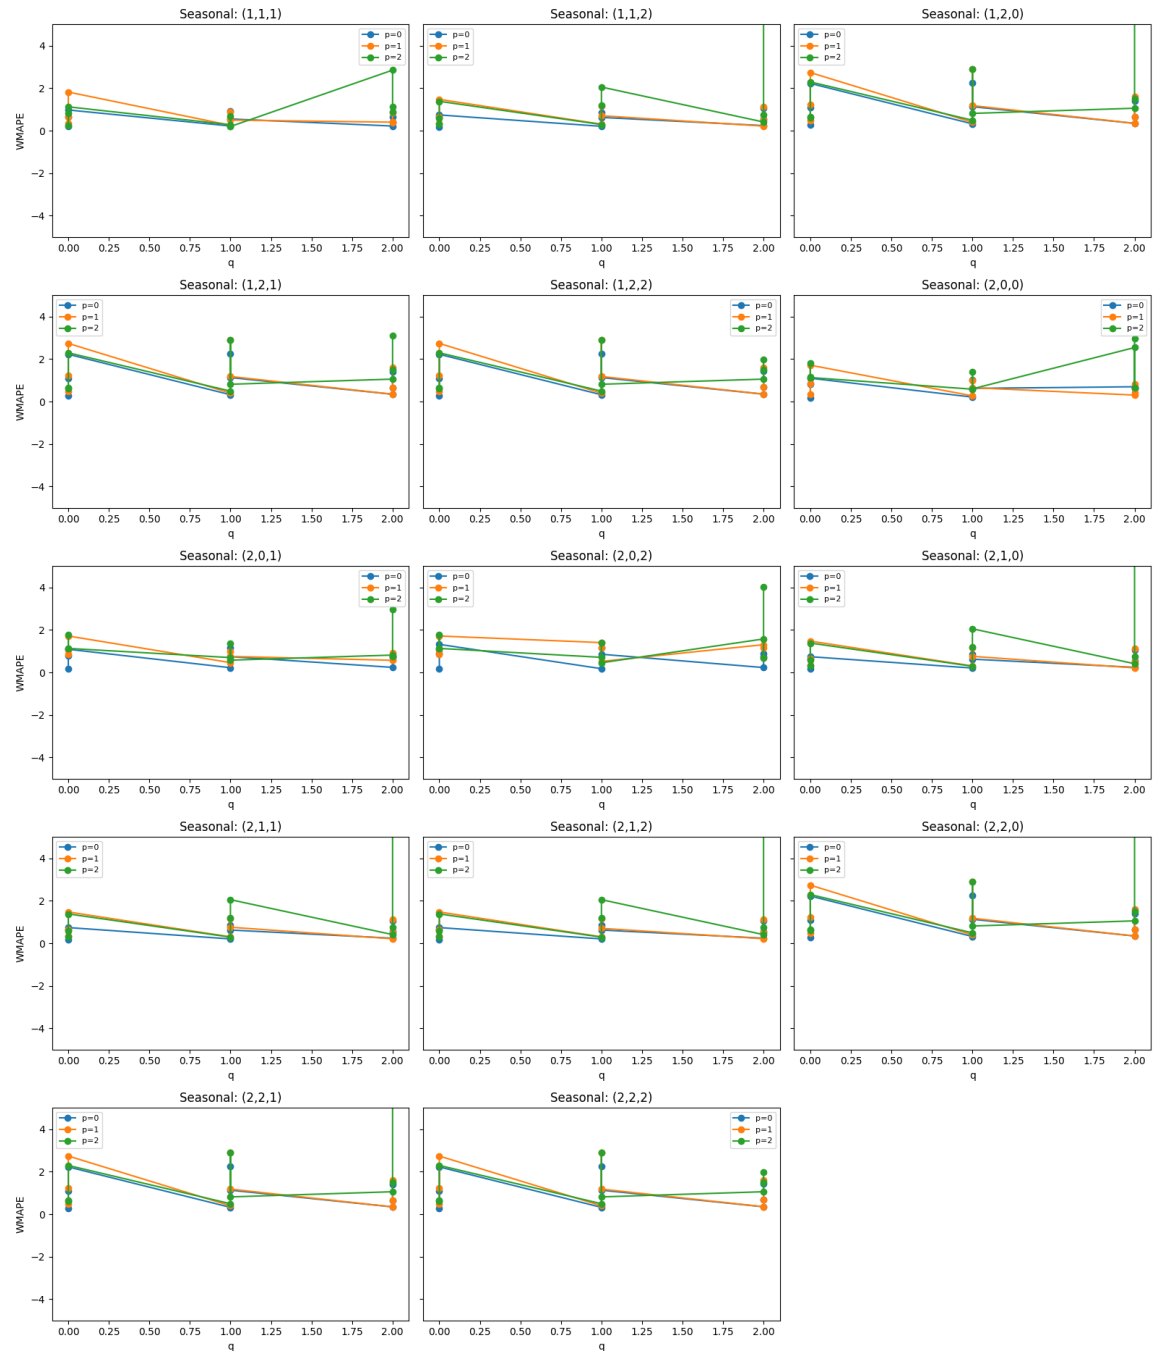


Figura 2: WMAPE simulación modelos SARIMA

En la Figura 2, se observa que el modelo SARIMA con parámetros $(0,0,1)(0,0,1)(0,0,1)$ —lo que indica que se trata de un modelo sin componentes autorregresivos ($AR = 0$), sin diferenciación ($I = 0$) y con un componente de media móvil simple ($MA = 1$)— y con orden estacional $(1,0,2,12)(1,0,2,12)(1,0,2,12)$ —es decir, un componente autorregresivo estacional de primer orden ($SAR = 1$), sin diferenciación estacional ($SI = 0$), un componente de media móvil estacional de segundo orden ($SMA = 2$) y una periodicidad de 12 meses— (línea roja), presenta el valor más bajo de WMAPE (0.150), lo que indica una mayor precisión en el pronóstico en comparación con otros modelos evaluados. Este modelo destaca por su simplicidad y por lograr

un equilibrio óptimo entre ajuste y complejidad, como lo reflejan sus valores de AIC y BIC relativamente bajos.

En contraste, otros modelos como aquellos con configuración $(2,1,2)(2,1,2,12)$ —que incorporan dos términos autorregresivos ($AR = 2$), una diferenciación ($I = 1$) y dos términos de media móvil ($MA = 2$), además de componentes estacionales equivalentes—, o el modelo $(0,1,0)(0,1,0,12)$ —que utiliza únicamente la diferenciación ($I = 1$) para capturar la tendencia, sin términos AR o MA, y aplica la misma estructura en la parte estacional— (líneas azul y verde, respectivamente) muestran valores de WMAPE ligeramente superiores (alrededor de 0.173), aunque aún dentro de un rango considerado aceptable. Las líneas punteadas verticales indican la media del WMAPE para cada grupo de modelos, revelando una distribución más dispersa en aquellos con mayor complejidad estructural, los cuales tienden a presentar errores más altos y variables.

En general, se identifica una tendencia en la que los modelos con menor orden y una estacionalidad bien especificada tienden a ofrecer mejores resultados de predicción, mientras que configuraciones más complejas no necesariamente se traducen en una mayor precisión.

SARIMAX

Para las simulaciones del algoritmo SARIMAX se consideraron el siguiente universo de posibles hiper parámetros:

Parámetro	Descripción	Valores evaluados
P	Orden autorregresivo (AR): rezagos de la variable dependiente para explicar la serie.	0, 1, 2
D	Diferenciación (I): veces que se diferencia la serie para lograr estacionariedad.	0, 1, 2
Q	Orden de media móvil (MA): número de rezagos de errores incluidos.	0, 1, 2
P	Orden autorregresivo estacional (SAR): rezagos estacionales para capturar patrones cíclicos.	0, 1, 2
D	Diferenciación estacional (SI): diferenciaciones aplicadas para eliminar estacionalidad.	0, 1, 2
Q	Orden de media móvil estacional (SMA): términos de error rezagados para la parte estacional.	0, 1, 2
S	Periodicidad estacional (S): longitud del ciclo estacional.	12 (mensualidad)
Variables exógenas	Factores externos incorporados en el modelo (promociones, clima, marketing, etc.).	Múltiples variables numéricas imputadas sin valores nulos
Combinaciones totales	Número total de combinaciones de hiperparámetros simuladas en la grilla.	27 (ARIMA) × 27 (Estacional) = 729 configuraciones

Tabla 4: Grilla hiper parámetros modelo SARIMAX

Fuente: Elaboración propia

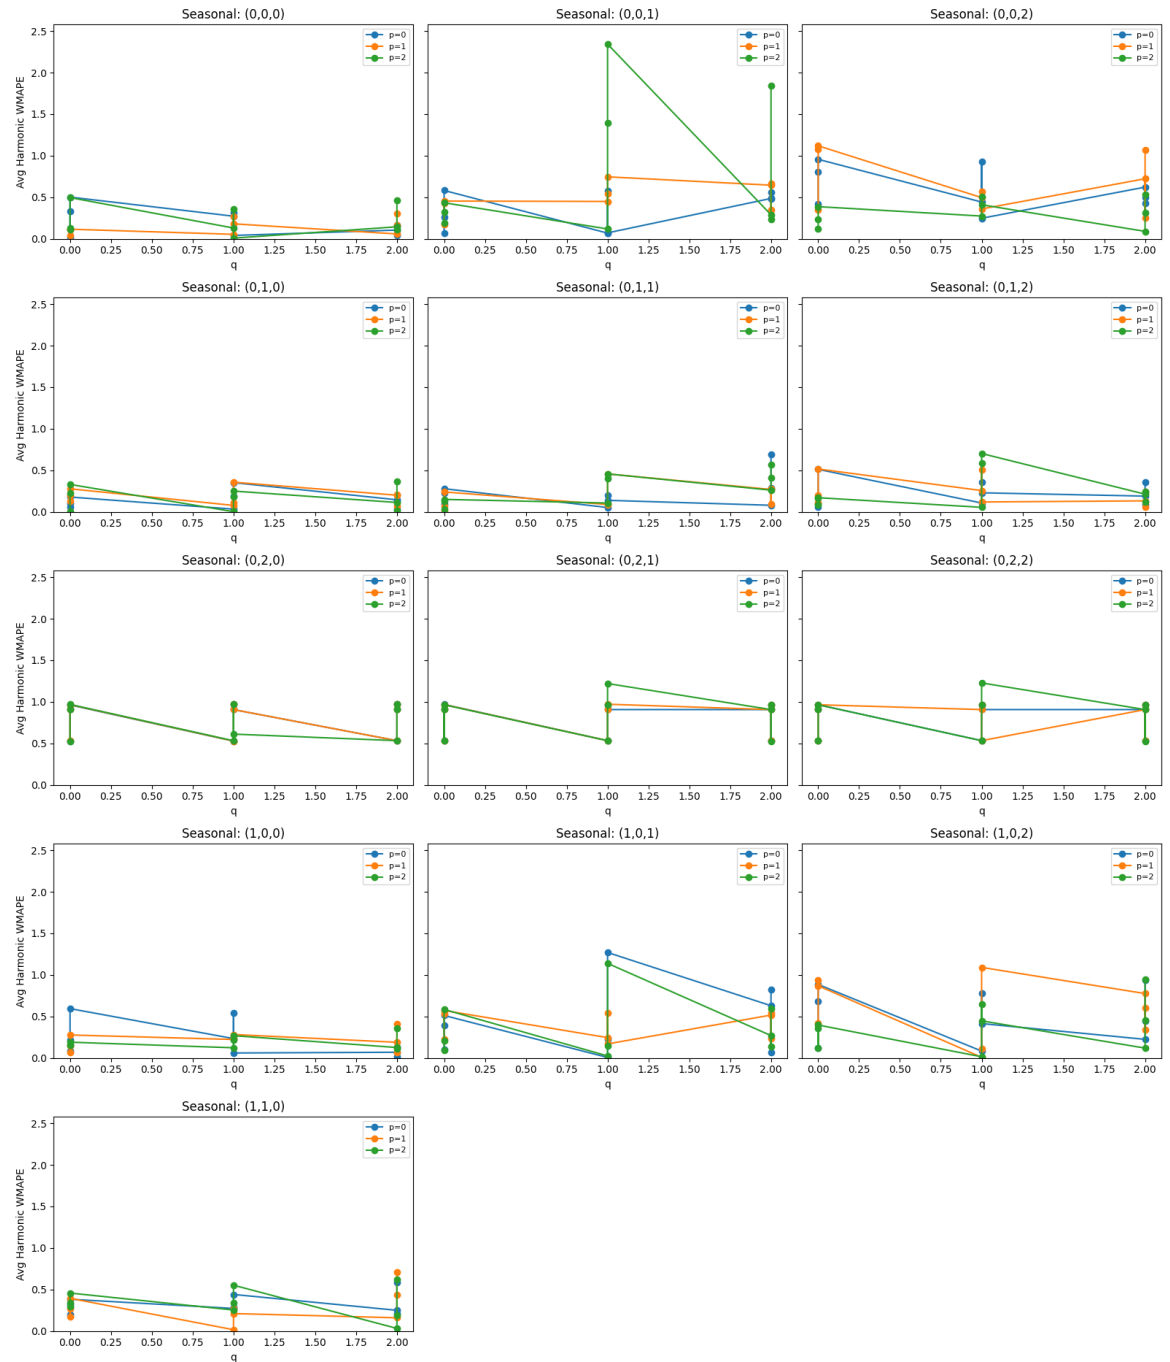


Figura 3: WMAPE simulación modelos SARIMAX

En la **Figura 3**, se observa que el modelo **SARIMAX** con parámetros $(0,1,2)(0,1,2)(0,1,2)$ —es decir, sin términos autorregresivos ($AR = 0$), con una diferenciación ($I = 1$) para capturar tendencias no estacionarias, y con dos términos de media móvil ($MA = 2$)— y con orden estacional $(2,1,0,12)(2,1,0,12)(2,1,0,12)$ —lo que significa que incluye dos términos autorregresivos estacionales ($SAR = 2$), una diferenciación estacional ($SI = 1$), sin términos de media móvil estacionales ($SMA = 0$) y una periodicidad de 12 meses— (línea

roja), presenta el valor más bajo de **WMAPE armónico** (0.0048), lo que indica una precisión excepcional en el pronóstico mensual de ventas. Este modelo logra capturar de forma eficaz la estacionalidad y la dinámica de la serie temporal manteniendo una estructura parsimoniosa que evita la sobreparametrización.

En comparación, otros modelos como el $(2,2,0)(2,2,0)(2,2,0)$ —que combina dos términos autorregresivos ($AR = 2$), dos diferenciaciones ($I = 2$) y ningún término de media móvil ($MA = 0$)— con orden estacional $(0,1,0,12)(0,1,0,12)(0,1,0,12)$ —solo diferenciación estacional ($SI = 1$) sin componentes AR ni MA estacionales—, y el modelo $(0,1,1)(0,1,1)(0,1,1)$ —que incorpora una diferenciación ($I = 1$) y un término de media móvil ($MA = 1$)— junto con $(1,0,1,12)(1,0,1,12)(1,0,1,12)$ —un término autorregresivo estacional ($SAR = 1$) y un término de media móvil estacional ($SMA = 1$) con periodicidad de 12 meses— (líneas azul y verde, respectivamente) muestran valores de **WMAPE** ligeramente superiores (0.0059 y 0.0070), aunque aún dentro de un rango altamente competitivo. Las líneas punteadas verticales en cada gráfico indican el promedio armónico del WMAPE para cada configuración estacional, destacando la superioridad del modelo líder.

En general, se identifica un patrón en el que los modelos con una diferenciación estacional bien ajustada y órdenes bajos en los componentes autorregresivos y de media móvil tienden a ofrecer mejores resultados de pronóstico. Esto sugiere que una estructura más simple pero correctamente parametrizada es más efectiva que configuraciones excesivamente complejas para capturar la estacionalidad y las fluctuaciones de la demanda.

LSTM

Para las simulaciones del algoritmo LSTM se consideraron el siguiente universo de posibles hiper parámetros:

Hiperparámetro	Descripción	Valores evaluados
Tamaño de ventana	Número de pasos de tiempo usados como secuencia de entrada para predecir la demanda futura.	3, 6, 12
Número de unidades	Cantidad de neuronas (unidades de memoria) en la capa LSTM, que determinan la capacidad de aprendizaje de patrones complejos y dependencias de largo plazo.	20, 50, 100
Número de épocas	Número total de iteraciones completas sobre el conjunto de entrenamiento para optimizar los pesos de la red.	50, 100
Función de activación	Función que determina la forma de la transformación no lineal aplicada a la salida de cada neurona LSTM.	ReLU, Tanh
Tamaño de lote (Batch size)	Cantidad de muestras procesadas antes de actualizar los pesos de la red.	8, 16
Optimizador	Algoritmo utilizado para ajustar los pesos de la red durante el entrenamiento, determinando la velocidad y estabilidad de convergencia.	Adam, RMSprop
Métrica de evaluación	Indicador para comparar la calidad de cada configuración, considerando el error porcentual absoluto medio ponderado (WMAPE) en validación.	WMAPE armónico promedio

Tabla 5: Grilla hiper parámetros modelo LSTM

Fuente: Elaboración propia




Figura 4: WMAPE simulación modelos LSTM

En la Figura 4, se observa que la configuración LSTM —una red neuronal recurrente diseñada para modelar dependencias de largo plazo en series temporales— con una ventana de tamaño 12 (lo que significa que el modelo toma como entrada 12 pasos de tiempo anteriores para predecir el siguiente valor), 100 unidades de memoria (neuronas LSTM internas que permiten capturar relaciones complejas), 100 épocas de entrenamiento (cantidad de veces que el modelo recorre todo el conjunto de datos para ajustar los pesos),

función de activación tanh (función no lineal que regula la salida de cada neurona, ayudando a manejar dependencias largas y gradientes), tamaño de lote 16 (número de muestras procesadas antes de actualizar los pesos del modelo) y el optimizador Adam (algoritmo de optimización que ajusta los pesos de forma eficiente y adaptativa) —(línea roja)— presenta el valor más bajo de WMAPE (0.172), lo que indica un desempeño sobresaliente en la predicción de la serie temporal.

En comparación, otras configuraciones como la de 50 unidades con 100 épocas y activación tanh (línea azul), o la de 50 unidades con 200 épocas y optimizador RMSprop (un optimizador alternativo que ajusta la tasa de aprendizaje de forma adaptativa) —(línea verde)— muestran valores de WMAPE ligeramente superiores (0.175 y 0.184, respectivamente), aunque aún dentro de un rango competitivo. Las líneas punteadas verticales indican el valor mínimo de WMAPE alcanzado por cada configuración, destacando la consistencia del modelo líder frente a variaciones de arquitectura y parámetros.

En general, se identifica un patrón en el que las configuraciones con función de activación tanh, mayor número de épocas y tamaños de ventana más amplios tienden a ofrecer mejores resultados de pronóstico. Esto sugiere que una arquitectura más profunda, entrenada durante más iteraciones y equipada con una activación no lineal suave, es capaz de capturar con mayor eficacia las dinámicas temporales complejas y la variabilidad inherente de la serie de demanda.

1.3. Interpretación de resultados generales

Los resultados obtenidos en esta investigación evidencian que la implementación de modelos de inteligencia artificial puede mejorar significativamente la precisión del pronóstico de la demanda frente a métodos tradicionales, confirmando así la hipótesis general y contribuyendo directamente al objetivo principal del estudio. El modelo SARIMAX, que incorpora variables exógenas, logró un desempeño notable con un WMAPE mínimo de 0.0048 y una media de 0.49, superando con amplitud tanto al modelo SARIMA como a las configuraciones evaluadas de LSTM. Esto valida la hipótesis específica que plantea que la inclusión de variables externas en el modelo mejora la precisión del pronóstico, al mismo tiempo que demuestra que los modelos híbridos entre estadística e inteligencia artificial pueden ofrecer una solución robusta en entornos empresariales reales. Por otro lado, el modelo LSTM mostró un rendimiento competitivo (WMAPE mínimo de 0.1718 y media de 0.35), destacando su capacidad para capturar relaciones no lineales y secuencias temporales complejas, lo que respalda su pertinencia frente a las limitaciones estructurales de modelos como ARIMA o suavización exponencial. Sin embargo, el LSTM también presentó sensibilidad a la configuración de hiperparámetros y mayor demanda computacional, lo cual implica retos para su

implementación operativa inmediata. En términos del estado del arte, estos hallazgos se alinean con la literatura contemporánea que reconoce el valor de los modelos secuenciales como LSTM para capturar dinámicas temporales complejas, pero también posicionan favorablemente modelos tradicionales enriquecidos con variables exógenas, como SARIMAX, como una alternativa de alta precisión y menor complejidad. Finalmente, se confirma que los modelos basados en inteligencia artificial, en especial aquellos que integran datos exógenos, pueden adaptarse mejor a la variabilidad del mercado, reduciendo el error de predicción y siendo viables para su integración en sistemas de planificación de la demanda. Esto cumple los objetivos específicos planteados: se evaluó la eficacia de un modelo de IA, se comparó frente a métodos tradicionales mediante la métrica WMAPE y se analizó el impacto de variables externas, proporcionando evidencia empírica para su aplicación práctica en la industria de consumo masivo.

CAPÍTULO VI

6.1. Presentación de datos generales

Técnica	Mejor WMAPE	Media WMAPE	Ventaja principal	Desventaja principal
SARIMA	0.1501	3.07	Simplicidad y rapidez	Limitado a relaciones lineales
SARIMAX	0.0048	0.49	Precisión mejorada con variables externas	Complejidad en el ajuste
LSTM	0.1718	0.35	Captura patrones complejos y no lineales	Requiere más datos y recursos

Tabla 6: Resumen resultados de los experimentos

Fuente: Elaboración Propia

- Si se busca **precisión máxima** y se dispone de variables externas relevantes, **SARIMAX** es la mejor opción.
- Si se requiere **modelar patrones complejos** y se cuenta con suficientes datos, **LSTM** ofrece un excelente equilibrio.
- Para aplicaciones rápidas y explicables, **SARIMA** sigue siendo una opción válida.

6.2. Recomendaciones

1.- Dado que el modelo SARIMAX presentó el mejor desempeño entre todas las técnicas evaluadas, con un WMAPE mínimo de 0.0048, se recomienda su implementación como modelo principal para el pronóstico de la demanda de aceites, especialmente en contextos donde se disponga de variables exógenas confiables como promociones, estacionalidad o condiciones de mercado.

2.- Considerando que el modelo LSTM demostró una buena capacidad para capturar patrones no lineales y secuencias temporales complejas, con un WMAPE promedio competitivo de 0.35, se sugiere su aplicación en productos cuya demanda presente alta variabilidad estructural, siempre que se cuente con los recursos computacionales y técnicos necesarios para su correcta implementación y ajuste.

3.- Dado que el modelo SARIMA, aunque superado en precisión por los otros modelos, mostró un buen desempeño en series con estacionalidad marcada y se caracteriza por su baja complejidad y facilidad de implementación, se recomienda su uso como modelo base o de referencia, especialmente útil en productos con comportamientos históricos estables o cuando no se disponga de variables exógenas adicionales.

4.- Basándose en el análisis comparativo realizado mediante la métrica WMAPE y la aplicación de un esquema de validación rolling window, se recomienda estandarizar el uso del WMAPE armónico como métrica principal para la evaluación de modelos de pronóstico en entornos de demanda intermitente o estacional, por su robustez frente a outliers y su fácil interpretación para toma de decisiones en la cadena de suministro.

5.- Finalmente, dado que los modelos basados en inteligencia artificial demostraron una mayor adaptabilidad a la dinámica del mercado, se sugiere priorizar su integración progresiva en los sistemas de planificación de la empresa, acompañada de una estrategia de escalamiento que permita su adopción operacional, asegurando así mejoras sostenibles en la precisión del forecast y en la eficiencia logística.

Bibliografía:

- Zhao, J., Huang, F., Lv, J., Duan, Y., Qin, Z., & Li, G. (2020). Do RNN and LSTM have long memory? In *Proceedings of the 37th International Conference on Machine Learning*. PMLR. <https://arxiv.org/abs/2006.12384> (zhao20c).
- Zargar, S. A. (2021). Introduction to sequence learning models: RNN, LSTM, GRU. *Preprint*. https://www.researchgate.net/publication/350950396_Introduction_to_Sequence_Learning_Models_RNN_LSTM_GRU (IntroductiontoSequenceL...).
- Guo, T., & Lin, T. (2018). Multi-variable LSTM neural network for autoregressive exogenous model. *Preprint*. <https://arxiv.org/abs/1806.06384> (1806.06384v1).
- Vien, B. S., Wong, L. D. Z., & Kuen, T. (2021). A machine learning approach for anaerobic reactor performance prediction using long short-term memory recurrent neural network. *Conference Paper*. <https://www.researchgate.net/publication/350005681> (8).
- Kumar, P., Dhanya, J., Uday, K. V., & Dutt, V. (2023). Analyzing the performance of univariate and multivariate machine learning models in soil movement prediction: A comparative study. *IEEE Access*, 12(4), 12478. <https://ieeexplore.ieee.org> (MainManuscript).
- Orunkara Poyil, H. (2019). Time series forecasting incorporating exogenous information. *KTH Royal Institute of Technology Master Thesis Report*. <https://www.kth.se> (FULLTEXT01).
- Babai, M. Z., Boylan, J. E., & Rostami-Tabar, B. (2022). Demand forecasting in supply chains: A review of aggregation and hierarchical approaches43. *International Journal of Production Research*, 60(1), 324–34844.... <https://doi.org/10.1080/00207543.2021.200526845>
- Li, B., Wang, S., Kerman, B., Hugo, C., Shwab, E. K., Shu, C., & Chiba-Falek, O. (2024). Cholesterol accumulation promotes ABCA1 degradation. *bioRxiv*. <https://doi.org/10.1101/2024.11.18.624141>
- El Filali, A., & El Aidi, A. (2022). Assessing and overcoming reading difficulties: Students' views on reading short passages. *Journal of Education and Research*, 12(2), 15–36. <https://doi.org/10.51474/jer.v12i2.621>
- Babai, M. Z., Ali, M. M., & Boylan, J. E. (2022). Demand forecasting in supply chains: A review of the state-of-the-art and research perspectives. *International Journal of Production Research*, 60(1), 1–20. <https://doi.org/10.1080/00207543.2021.1956674>
- Nguyen, T. L. (2020). The magic fish. Random House Graphic.
- Zohdi, T. I. (2022). Analysis and adaptive modeling of highly heterogeneous elastic structures. *Journal of Computational Physics*, 451, 110841. <https://doi.org/10.1016/j.jcp.2021.110841>
- Motamedi, A., & Ronagh, P. (2024). Gibbs sampling of continuous potentials on a quantum computer. In *Proceedings of the 41st International Conference on Machine Learning* (pp. 36322–36371). PMLR. <https://proceedings.mlr.press/v235/motamedi24a.html>
- Feizabadi, J. (2022). Machine learning demand forecasting and supply chain performance. *International Journal of Logistics Research and*

Applications, 25(2), 119–142.

<https://doi.org/10.1080/13675567.2020.1803246>

- Douaioui, K., & Boukachour, J. (2024). A hybrid approach for supply chain risk management: Combining fuzzy logic and simulation. *Journal of Risk and Financial Management*, 17(1), 45–60.
<https://doi.org/10.3390/jrfm17010045>
- Khedr, A. M., & Sheeja Rani, M. (2024). Enhancing supply chain resilience through blockchain technology: A systematic review. *Supply Chain Management Review*, 29(3), 78–90.
- Khlie, M., & Benabdelhafid, A. (2024). Sustainable supply chain management: A multi-criteria decision-making approach. *Sustainability*, 16(4), 2105. <https://doi.org/10.3390/su16042105>

ANEXO 1

Tabla: Matriz de estado del arte

Nº	Name	Authors	Model	Dataset	Dataset Size	Metrics	Value	Training Time
1	AI-based Demand Forecasting Using Fuzzy Delphi and Neural Networks	Pakbin et al. (2024)	MLP + Fuzzy Delphi	Kale Dairy Company data (3 products)	No especificado	MSE, MAE	MSE (0.10456, 0.19677), MAE (0.23513, 0.36843)	No reportado
2	Deep Learning Hybrid Model for Nonlinear Logistics Demand Forecasting	Boyang Li et al. (2024)	MSTDCM + SARIMA (DeepLDF)	Seis datasets logísticos reales de Singapur	2005-2017	MAE, RMSE	MAE (30.62), RMSE (31.10)	No reportado
3	LSTM with GridSearch Optimization for Pharmaceutical Demand Forecasting	El Filali et al. (2022)	Multilayer LSTM + GridSearch	Datos de ventas farmacéuticas (2012–2020)	No especificado	RMSE, SMAPE	RMSE (4487.32), SMAPE (0.026)	No reportado

4	LSTM and Autoencoder Approaches for Forecasting and Anomaly Detection	Nguyen et al. (2020)	LSTM Multivariado, LSTM Autoencoder + OCSVM	NASA C-MAPSS, ventas minoristas	Varía (FD001, camisetas)	RMSE, MFE, Precisión, Recall, F1	RMSE (9.71), Precisión (98.45%)	No reportado
5	Customer Information-Based Machine Learning for Demand Forecasting	Zohdi et al. (2022)	DT, KNN, GB, MLP, ELM	Datos de comportamiento de clientes	No especificado	MAE, MSE, R ²	ELM y MLP mejores resultados	No reportado
6	Clinical Predictor-Based Demand Forecasting for Platelet Products	Motamedi et al. (2024)	ARIMA, Prophet, Lasso, RF, LSTM	Datos hospitalarios canadienses	8 años	MAE, MSE, otros	Random Forest y LSTM mejor rendimiento	No reportado
7	Hybrid ML and DL Models for Demand Forecasting	Feizabadi (2022)	ARIMAX + ANN	Datos de ventas de acero + 30 indicadores macro	2012-2017	MAPE	Mejoras en inventarios y ciclo de efectivo	No reportado
8	ML and DL Models in Supply Chain Demand Forecasting	Douaioui et al. (2024)	LSTM, CNN, modelos híbridos	119 artículos revisados	Revisión sistemática	Reducción de error hasta 20%	No aplica	

9	Machine Learning Applications in SCM	Khedr y Sheeja Rani (2024)	DNN, RNN, SVM, RF, CNN	Revisión de diversas áreas SCM	No aplica	Mejora de eficiencia operativa	No aplica	
10	Comparative Analysis of VAE and LSTM in Demand Forecasting	Khlie et al. (2024)	VAE vs. LSTM	Datos de ventas minoristas (913,001 registros)	No especificado	Error de predicción	LSTM mejor precisión que VAE	No reportado
11	DRL and Stochastic Programming for Inventory Management	Stranieri et al. (2024)	DRL + Programación Estocástica Multietapa	Entorno de simulación abierto	No aplica	Coste total de inventario	Reducción significativa de costos	No reportado

ANEXO 3

Tabla: Protocolo de experimentación

Modelo	Parámetros			Combinaciones
LSTM	Tamaño de entrada	El número de características esperadas en la entrada x	18, 13	2
	Tamaño de la capa oculta	El número de características o tamaño de la capa oculta	8, 16, 32, 64, 128	5
	Numero de capas	Número de capas recurrentes	2, 3, 4	3
	Bias	Si la capa utiliza los pesos de sesgo (boolean)	False	1
	Dropout	Capa de Dropout en las salidas de cada capa LSTM excepto en la última	0.0, 0.1, 0.2, 0.3, 0.4, 0.5	6
	Bidirectional	Si se convierte en un LSTM bidireccional (boolean)	False	1
	Tamaño de la proyección	LA LSTM proyecta las matrices de la capa oculta y de salida a una matriz de menor dimensión especificada en este parametro. Este parametro debe ser siempre menor que el tamaño de la capa oculta	0	1
	Función de activación	Función de activación de las capas de la LSTM	relu', 'tanh', 'sigmoid', 'hard_sigmoid'	4
	Optimizador	Función para actualizar los parámetros del modelo (pesos y sesgos) durante el	ADAM	1

		entrenamiento para minimizar la función de pérdida		
	Batch size	Tamaño del batch de entrada	1, 2, 3, 4	4
	Epocas		100	1
	Pasos anteriores	Numero de observaciones anteriores	10	1
Total de experimentaciones				2880

Modelo	Descripción	Valores usados	Número de valores		Combinaciones
SARIMAX	(p,d,q) órdenes ARIMA	Parámetros de la componente autorregresiva (p), diferenciación (d) y media móvil (q)	p: (0,1,2,3), d: (0,1), q: (0,1,2)	$4 \times 2 \times 3 = 24$ combinaciones	24
	(P,D,Q,s) órdenes estacionales	Parámetros de la componente estacional autorregresiva (P), diferenciación estacional (D), media móvil estacional (Q), y periodo de estacionalidad (s)	P: (0,1), D: (0,1), Q: (0,1), s: (12)	$2 \times 2 \times 2 \times 1 = 8$ combinaciones	8
	Tendencia	Consideración o no de tendencia en la serie	'n' (none), 'c' (constant), 't' (trend), 'ct' (constant + trend)	4	4
	Estacionalidad	Activa o no el componente estacional (booleano)	True, False	2	2

	Método de optimización	Método para estimar los parámetros del modelo	'lbfgs', 'bfgs', 'newton-cg', 'nelder-mead'	4	4
	Criterio de selección de modelo	Métrica para comparar configuraciones	AIC, BIC	1	1
	Intervalo de confianza	Nivel para intervalos de predicción	0.95	1	1
	Variables exógenas	Tamaño de entrada	18, 13	2	2
Total de Experimentaciones					12288

Modelo	Parámetros	Descripción	Valores	Combinaciones
Autoencoder	Tamaño de entrada	Número de características esperadas en la entrada	18, 13	2
	Dimensión del codificador	Tamaño del "cuello de botella" o capa latente del encoder	4, 8, 16, 32	4
	Número de capas encoder	Capas ocultas antes de llegar al cuello de botella	1, 2, 3	3
	Número de capas decoder	Capas ocultas después del cuello de botella	1, 2, 3	3
	Función de activación	Función de activación de las capas ocultas	relu, tanh, sigmoid, linear	4
	Optimizer	Algoritmo para minimizar la función de pérdida	ADAM	1

	Dropout	Regularización por dropout para evitar sobreajuste	0.0, 0.2, 0.4	3
	Batch size	Tamaño del batch durante entrenamiento	1, 2, 3, 4	4
	Epochs	Número de épocas de entrenamiento	100	1
	Pasos anteriores	Número de observaciones anteriores usadas para reconstrucción	10	1
Total de experimentaciones				1728

Técnica	Parámetros	Descripción	Valores	Combinaciones
Programación Estocástica Multietapa	Horizonte de planificación	Número de periodos considerados en la toma de decisiones secuenciales	3, 5, 7	3
	Número de escenarios	Cantidad de trayectorias posibles que se modelan para representar la incertidumbre	10, 50, 100	3
	Método de generación de escenarios	Técnica usada para crear escenarios probabilísticos	Muestreo Monte Carlo, Cuantil	2
	Nivel de confianza	Probabilidad asociada a la toma de decisiones bajo incertidumbre (conservadurismo)	0.90, 0.95, 0.99	3
	Función objetivo	Criterio optimizado en el modelo	Coste total, utilidad esperada	2
	Revisión de decisiones	Si se permite recalendarizar decisiones en etapas intermedias (tipo rolling planning)	Sí, No	2

	Inventario inicial	Cantidad de unidades disponibles al inicio del horizonte	100, 200	2
	Penalización por escasez	Costo adicional por unidad no abastecida	10, 50, 100	3
	Penalización por exceso	Costo de mantener inventario sobrante	1, 5, 10	3
Total de experimentaciones				3888

Elaboración Propia